

Hello Quants!

BRAIN Platform

브레인 플랫폼을 시작하시게 된 것을 환영합니다! 브레인은 퀀트 아이디어를 표현하고 직접 백테스트까지 돌려볼 수 있는 플랫폼입니다.

주가를 예측하는 수학적 모델을 브레인 플랫폼에서는 알파라고 부르는데요, 브레인 플랫폼에서는 알파를 백테스트하고 결과를 확인하며, 좋은 알파는 제출까지 하실 수 있습니다.

컨설턴트 레벨이 되신 다음 좋은 알파를 제출하면, 그에 따르는 소정의 보상도 제공해드리고 있습니다. 컨설턴트 프로그램과 관련해서는 차차 자세히 설명드리도록 하겠습니다 😊

Stock Market

주식시장 하면 무엇이 생각나나요? 주식에 투자해서 수익을 올릴 수 있다는 점이 떠오를 것입니다. 투자자는 어떤 주식에 대해서 그 주식이 오를 것인지, 아니면 내릴 것인지에 대해서 배팅을 하고 그에 따라 수익 또는 손실을 보게 되죠.

Quantitative investing

퀀트투자라는 것은 무엇일까요? 퀀트투자는 주식들의 특성성에 대해서 미리 정해진 수학적 모델을 통해서 긍정의 개입 없이 투자를 하겠다는 것을 의미합니다. 언제 얼마만큼을 어느 주식에 투자할 것인지 규칙을 미리 정의해 두고, 그에 맞춰서 투자를 하겠다는 것이죠.

이런 규칙이 잘 작동하는지 확인하기 위해 우리는 백테스트라는 과정을 거쳐야 합니다. 특징은 규칙이 과거에 잘 작동했는지를 확인해보고, 그 결과에 따라 실제로 투자를 할지를 결정해야하는 것입니다.

Let's try out!

브레인에서는 화면 왼쪽의 섹션에 이러한 규칙을 코드로 작성하고, 그 결과를 확인해 볼 수 있습니다. 가장 간단한 예시를 하나 들어볼까요?

왼쪽 화면에 **-returns**라는 코드를 입력하고, **Simulate** 버튼을 눌러 보세요.

힌트: **-returns**를 입력하고 시뮬레이션해보세요.

예시답안: **-returns**

What is Alpha? (1)



What does **-returns** mean?

방금 돌려본 수식을 자세히 살펴보겠습니다. 먼저 **returns**는 각 날짜의 각 기업의 주가수익률을 담고 있는 데이터필드입니다.

그리고 **returns**에 마이너스 부호를 붙여주었죠? 이는 **returns**의 반대로 베팅하겠다는 것을 의미합니다.

따라서 우리가 방금 돌려본 수식은 업별 수익률의 반대로 투자를 해보겠다는 아이디어를 수식화한 것이죠. 즉 어제의 수익률이 높았던 기업들은 앞으로 가격이 오를 것이고, 낮았던 기업들은 앞으로 가격이 내릴 것이라고 예측한 것입니다.

보시다시피, 수익률과 반대로 투자하는 것만으로도 상당히 괜찮은 수익을 내는 알파가 되는 것을 볼 수 있습니다. 이를 우리는 **Price Reversion**이라고 부릅니다. 여기에 대해서는 곧 더 자세히 살펴보도록 하겠습니다.



What is Alpha?

이렇게 주가 움직임의 예측을 수식으로 나타낸 것을 알파라고 하고, 브레인에서는 알파를 오퍼레이터와 데이터필드의 조합으로 표현하게 됩니다.



Operators

오퍼레이터를 통해서 데이터필드를 변형할 수 있는데요, 앞서 **returns** 앞에 붙여준 마이너스 또한 오퍼레이터의 일종이라고 볼 수 있습니다.



Let's try out!

이번에는 **rank()**라는 오퍼레이터를 사용해 보겠습니다. 앞서 돌린 **-returns**에 **rank()**를 씌워서 알파를 만들어 보세요.

-returns에 **rank()**를 씌워서 알파를 시뮬레이션해 보세요.

힌트: **rank(-returns)**를 입력하고 시뮬레이션해보세요.

예시답안: **rank(-returns)**

What is Alpha? (2)



알파 성과 지표 자세히 살펴보기

알파를 시뮬레이션해보시면 여러가지 결과가 뜨는 것을 확인하실 수 있는데요, 하나하나 살펴보면서 설명을 드려보겠습니다.



PnL 그래프



알파를 백테스트하면 투자의 결과에 따라 이익과 손해가 발생하게 됩니다. 그것을 백테스트 기간에 걸쳐 누적해놓은 것을 **PnL (Profit and Loss)** 이라고 하고, **Result** 페이지에서는 이를 그래프로 확인해보실 수 있습니다.



IS Summary

알파를 시뮬레이션하면 브레인 플랫폼은 결과를 대표하는 값들을 요약해서 **IS Summary**에 나타내어줍니다.

Sharpe

얼마나 많은 수익을 얻는가도 중요하지만, 얼마나 수익을 안정적으로 얻는가도 굉장히 중요한 알파의 평가요소가 됩니다. **Sharpe**는 수익을 수익의 표준편차로 나눠준 것을 연율화($\sqrt{252}$)한 값을 의미합니다.

Turnover

알파를 작성을 하면 하루하루의 포지션이 달라지게 되는데요, ****턴오버(Turnover)****는 하루마다 평균적으로 얼마나 포지션이 변경되었는가를 의미합니다. 이는 **Value Traded / Value Held**라는 수식으로 표현됩니다.

Fitness

Fitness는 월드퀀트에서 알파의 성과를 평가하는 독자적인 평가 기준입니다. 알파의 샤프가 높으면 좋다고 생각할 수도 있겠지만, 턴오버가 너무 높은 경우는 너무 많은 거래가 필요해서 트레이드가 어려워지는 상황을 발생할 수도 있습니다. 그렇기 때문에 샤프를 턴오버로 나눠주고, 얼마나 수익을 얻는지에 대한 지표인 **return**의 제곱근을 곱해주면 거래 가능성을 고려한 알파의 성과를 잘 측정할 수 있는 지표가 됩니다. **Fitness**는 $\text{Sharpe} * \sqrt{\text{Abs}(\text{Returns})} / \text{Max}(\text{Turnover}, 0.125)$ 의 수식으로 나타내어집니다.

Returns

Returns는 알파가 얼마만큼의 수익을 낼 수 있는가를 나타내는 지표입니다. 브레인플랫폼의 시뮬레이션은 롱-숏 포트폴리오(여기에 대해서는 다음 스텝에서 설명드리겠습니다.)를 전제로 하기 때문에, 전체투자의 양을 **book size**의 절반으로 정의하고 있습니다.

Drawdown

알파의 성과가 좋더라도, 특정 기간에 손실이 크게 발생하는 경우가 발생할 수 있습니다. 시장 상황에 따라 달라지겠지만, 보통 손실이 크게 발생하면 해당 알파에 투자를 계속하는 것이 어려워질 수 있습니다. **Drawdown**은 이를 측정하는 지표가 되는데요, 시뮬레이션의 기간 동안에 가장 크게 발생했던 손실의 규모를 의미합니다.

Margin

Margin은 트레이드한 양에 비해 얼마만큼의 **PnL**을 얻었는지를 의미합니다. 이를 계산하기 위해서, 총 **PnL**을 거래된 전체 양으로 나눠주게 됩니다. **Margin**의 단위는 %가 아니라 **bps(‰)**임에 유의하세요!

Let's try out!

알파의 성과 지표에 유의해서 자유롭게 알파를 작성하여 시뮬레이션해보세요. 알파의 내용과 관계 없이 시뮬레이션이 완료되면 다음 스텝으로 넘어갈 수 있습니다.

원하는 알파를 자유롭게 시뮬레이션하고 결과를 확인해보세요.

힌트: 원하는 알파를 자유롭게 시뮬레이션하고 결과를 확인해보세요.

예시답안: `vwap/close`

What's going on in the platform? (1)



시뮬레이션을 실행했을 때 플랫폼에서 일어나는 일



Position

시뮬레이션을 시작하면, 브레인에서는 각 주식에 포지션을 설정하여 각 주식에 얼마만큼을 투자할 것인지를 계산합니다.

포지션은 크게 롱포지션과 숏포지션으로 구성되는데요, 브레인에서의 롱포지션은 주식을 사는 것을 말하며 앞으로 주식이 오를 것이라는 데에 베팅한다는 것을 의미합니다. 반대로 숏포지션은 주식을 파는 것을 말하며 앞으로 주식이 내릴 것이라는 데에 베팅한다는 것을 의미하죠.

시뮬레이션 버튼을 누르면, 브레인 플랫폼에서는 다음의 표에 나타난 과정을 거치면서 각 주식의 포지션을 계산합니다. 복잡해 보이지만 너무 걱정치 마세요! 차근차근 살펴보면 간단합니다.

	B	C	D	E	F	G	H	I	J	K	L
1	How does the Expression become a PnL curve										
	Stocks in the Alpha vector	Stock Returns on 1-Feb	Alpha value on 2-Feb: rank(-returns)	Subtract Average	Centred around 0	Absolute value	Normalized weights on 2-Feb	Absolute value	Allocate \$ 20 Mn capital (Position on 2nd Feb)	Suppose Returns on 2 Feb are	\$Mn profits on 2 Feb would be
3	Stock 1	3.0%	0.00	(0.50)	-0.5	0.50	-0.22	0.22	-4.4	2.0%	-0.09
4	Stock 2	2.5%	0.14	(0.50)	-0.4	0.36	-0.16	0.16	-3.1	2.0%	-0.06
5	Stock 3	1.8%	0.29	(0.50)	-0.2	0.21	-0.09	0.09	-1.9	-2.1%	0.04
6	Stock 4	0.6%	0.43	(0.50)	-0.1	0.07	-0.03	0.03	-0.6	-2.1%	0.01
7	Stock 5	0.2%	0.57	(0.50)	0.1	0.07	0.03	0.03	0.6	1.0%	0.01
8	Stock 6	-0.9%	0.71	(0.50)	0.2	0.21	0.09	0.09	1.9	0.0%	0.00
9	Stock 7	-1.7%	0.86	(0.50)	0.4	0.36	0.16	0.16	3.1	1.0%	0.03
10	Stock 8	-2.8%	1.00	(0.50)	0.5	0.50	0.22	0.22	4.4	2.0%	0.09
11	Sum				-1.1 + 1.1	2.3	-0.5 + 0.5	1.0	+10 M -10 M		0.03
12	Mean		0.50		0.0		0.0	Normalized	0.0		P&L



1. Expression Calculation

하나하나 살펴보도록 하겠습니다. 가장 먼저 시뮬레이터는 Expression 내에 있는 주식의 결과를 계산합니다.

****rank()****는 오퍼레이터 내의 입력값의 순서를 매긴 뒤, 큰 순서대로 1부터 0까지 골고루 간격으로 배열합니다. 예컨대 5개의 주식이 대상이라고 하면 입력값의 순서에 따라 **0, 0.25, 0.5, 0.75, 1** 이렇게 5개의 값을 반환합니다.

위의 표에서는 이 과정이 D열, **Alpha value on 2-Feb: rank(-returns)** 열에 표시되어 있습니다.

주식이 정상적으로 계산되면, 그 이후에는 중립화라는 과정을 거치게 됩니다.



2. Market Neutralization

중립화는 어떠한 알파에서 특정 영향을 제거해준다는 것을 의미합니다. 주식의 가격은 시장 전체의 움직임에 영향을 받는 경우가 많기 때문에, 수많은 주식들을 대상으로 롱포지션만 가져가게 되면 시장 위험에 노출될 위험이 높습니다.

그래서 브레인에서는 정반의 포지션은 롱포지션으로, 나머지 절반은 숏포지션으로 가져가는 롱-숏 포트폴리오를 구성하는 것을 전제로 합니다.

롱-숏 포트폴리오를 구성하기 전에, 롱포지션만 가져가면 어떤 일이 일어나는지 확인해 봅시다. **Settings**를 클릭한 다음에, **Neutralization**을 **None**으로 변경해 본 뒤 결과를 확인해보세요.

USA/D1/TOP3000 Settings

LANGUAGE: Fast Expression

INSTRUMENT TYPE: Equity

REGION: USA

UNIVERSE: TOP3000

DELAY: 1

NEUTRALIZATION: Subindustry

LOOKBACK DAYS: 256

DECAY: 4

TRUNCATION: 0.1

PASTEURIZATION: On

UNIT HANDLING: Verify

NAN HANDLING: Off

Save as Default Apply

앞서 본 것처럼 **rank** 오퍼레이터를 적용하면 최소 0부터 최대 1까지의 값을 갖게 되기 때문에, 롱포지션만 가져가는 **long-only** 포트폴리오를 구성할 수 있습니다.

Settings에서 **Neutralization**을 **None**으로 변경하고 결과를 확인해 보세요.

힌트: **Settings**에서 **Neutralization**을 **None**으로 설정하고 알파를 시뮬레이션해보세요.


예시답안: # Neutralization: None

rank(-returns)

What's going on in the platform? (2)

⚖️ 시장 중립화

📊 long-only portfolio



앞의 시뮬레이션 결과와 반대되는 **rank(returns)**를 해도 비슷한 개형을 나타내는 것을 볼 수 있습니다. 결국 롱 포지션으로만 구성되는 포트폴리오는 시장위험의 영향을 벗어나기 힘들다는 것을 의미합니다.

그렇기 때문에 브레인에서는 포트폴리오에서 시장위험의 영향을 최소화하고 순수한 시그널의 영향만을 남기기 위해 절반의 포지션은 롱포지션으로, 나머지 절반은 숏포지션으로 가져가는 롱-숏 포트폴리오를 구성하는 것을 전제로 합니다.

⚖️ long-short portfolio

다시 아까 보았던 표로 돌아와보겠습니다. 시장위험을 중립화하기 위해서는 크게 세 가지의 전제를 거치게 됩니다.

1. 각각의 값에서 평균을 뺀 주어 중립을 0으로 맞추어 줍니다. **(Centered around 0)**
2. 각각의 값을 절대값의 합으로 나눠주어 절대값의 총합이 1이 되는 **Normalized weights**를 만듭니다. **(Normalized weights)**
3. **Normalized weights**에 **book size**를 곱해주어 실제 포지션을 구합니다. **(Allocate \$20Mn capital)**

	B	C	D	E	F	G	H	I	J	K	L
1	How does the Expression become a PnL curve										
2	Stocks in the Alpha vector	Stock Returns on 1-Feb	Alpha value on 2-Feb : rank(-returns)	Subtract Average	Centred around 0	Absolute value	Normalized weights on 2-Feb	Absolute value	Allocate \$ 20 Mn capital (Position on 2nd Feb)	Suppose Returns on 2 Feb are	\$Mn profits on 2 Feb would be
3	Stock 1	3.0%	0.00	(0.50)	-0.5	0.50	-0.22	0.22	-4.4	2.0%	-0.09
4	Stock 2	2.5%	0.14	(0.50)	-0.4	0.36	-0.16	0.16	-3.1	2.0%	-0.06
5	Stock 3	1.8%	0.29	(0.50)	-0.2	0.21	-0.09	0.09	-1.9	-2.1%	0.04
6	Stock 4	0.6%	0.43	(0.50)	-0.1	0.07	-0.03	0.03	-0.6	-2.1%	0.01
7	Stock 5	0.2%	0.57	(0.50)	0.1	0.07	0.03	0.03	0.6	1.0%	0.01
8	Stock 6	-0.9%	0.71	(0.50)	0.2	0.21	0.09	0.09	1.9	0.0%	0.00
9	Stock 7	-1.7%	0.86	(0.50)	0.4	0.36	0.16	0.16	3.1	1.0%	0.03
10	Stock 8	-2.8%	1.00	(0.50)	0.5	0.50	0.22	0.22	4.4	2.0%	0.09
11	Sum				-1.1 + 1.1	2.3	-0.5 + 0.5	1.0	+10 M -10 M		0.03
12	Mean		0.50		0.0		0.0	Normalized	0.0		P&L

하루하루 이 세가지의 과정을 거쳐 포지션을 만든 후, 날마다 각 주식의 PnL을 계산한 뒤 합쳐서 최종 PnL을 산출하게 되는 것입니다.

위의 표에서는 총 8개 주식 중 5개 주식의 예측이 맞고 2개의 예측은 틀리게 되어 최종적으로 0.03의 수익이 난 것을 확인할 수 있습니다.

Decay

가끔 알파의 포지션이 날마다 너무 많이 바뀌게 되는 경우가 있을 수 있습니다. 예컨대 예시에서 살펴 본 ****rank(-returns)****의 경우는 날마다 주가수익률이 반대가 된다는 것인데, 이 알파의 전제가 참이라면 날마다 모든 주식의 롱 숏 포지션이 모두 바뀌어야 하겠지요?

그러나 하루에 너무 많은 포지션을 변경하게 되면 거래의 가능성이나 비용, 슬리피지 등의 문제들이 발생할 수 있어서, 실제로는 거래가 거의 불가능한 알파가 될 가능성이 높습니다.

이러한 경우에는 **Decay**라는 방법을 통해서 알파의 포지션이 변하는 속도를 늦춰줄 수 있습니다.

Decay는 과거의 포지션을 현재에 일정 부분 들고오는 것입니다. 오늘의 포지션을 정할 때, 일정 비율만큼은 어제나 그제께의 포지션을 그대로 적용하겠다는 것이죠.

아래 표를 통해서 설명해보겠습니다.

	B	H	I	J	K	L	M	N	O	P
1	How does the									
2	Stocks in the Alpha vector	Normalized weights on 2-Feb	Absolute value	Allocate \$ 20 Mn capital (Position on 2nd Feb)	Suppose Returns on 2 Feb are	\$Mn profits on 2 Feb would be		Decay = 3		
3	Stock 1	-0.22	0.22	-4.4	2.0%	-0.09		Normalized weights on 1-Feb	Normalized weights on 31-Jan	Final weight after Decay
4	Stock 2	-0.16	0.16	-3.1	2.0%	-0.06		-0.03	0.03	-0.11
5	Stock 3	-0.09	0.09	-1.9	-2.1%	0.04		-0.16	-0.03	-0.14
6	Stock 4	-0.03	0.03	-0.6	-2.1%	0.01		-0.22	0.09	-0.11
7	Stock 5	0.03	0.03	0.6	1.0%	0.01		0.03	-0.16	-0.03
8	Stock 6	0.09	0.09	1.9	0.0%	0.00		-0.09	0.22	0.02
9	Stock 7	0.16	0.16	3.1	1.0%	0.03		0.22	-0.22	0.08
10	Stock 8	0.22	0.22	4.4	2.0%	0.09		0.09	0.16	0.13
11	Sum	-0.5 + 0.5	1.0	+10 M -10 M		0.03		0.16	-0.09	0.15
12	Mean	0.0	Normalized	0.0		P&L				

3일의 Decay를 적용한다면 최종적으로 산출된 오늘의 포지션(2-Feb)에 3을, 어제의 포지션(1-Feb)에는 2를, 그제께의 포지션(31-Jan)에는 1를 곱하여 가중평균한 값을 최종 포지션으로 가져가게 되는 것입니다.

이를 수식으로 표현하면 $(\text{Position}(\text{02Feb}) * 3 + \text{Position}(\text{01Feb}) * 2 + \text{Position}(\text{31Jan}) * 1) / 6$ 이 됩니다. 일반화하여 나타내면 다음과 같습니다.

$$\text{Decay_linear}(x, n) = \frac{x[\text{date}] * n + x[\text{date} - 1] * (n - 1) + \dots + x[\text{date} - n + 1] * 1}{n + (n - 1) + \dots + 1}$$

Decay는 포지션이 변하는 속도를 쉽게 조절해줍니다. 다만 **Decay**를 적용할 경우에는 현재의 알파 값이 느리게 반영되게 되므로 시그널의 세기는 약해질 수 있다는 것에 유의해야 합니다. 통상적으로 **Decay**에는 10 이내의 값을 활용합니다.

그렇다면 시장 중립화와 **Decay**를 적용한 알파를 한 번 만들어 볼까요?

Settings에서 **Neutralization**을 **Market**으로 적용하고, **Decay**에 3 이상의 값을 적용하여 알파를 시뮬레이션해보세요.

힌트: **Settings**에서 **Neutralization**을 **Market**으로 설정하고 **Decay**를 3 이상으로 설정해보세요.

예시답안:

```
# Neutralization: Market, Decay > 3
rank(-returns)
```

Settings

Language / Instrument Type

이제 세팅에 있는 각 항목들에 대해서 설명을 드려보겠습니다. 세팅을 한 번 켜놓고 살펴봅시다.

먼저 **Language**와 **Instrument Type**은 하나로 묶어서 소개되어 있는데요. 브레인 플랫폼에서는 주식(Equity) 종목들만을 대상으로 **Fast Expression**이라는 간소화된 언어로 백테스트 시뮬레이션을 지원하고 있습니다. **Fast Expression**에 대해서 걱정은 할 필요는 없습니다. 천천히 자세하게 알려드릴게요!

Region

Region은 어느 지역의 주식들을 대상으로 시뮬레이션을 할 것인지 설정하는 것입니다.

현재는 미국(USA)과 중국(CHN), 이렇게 두 가지 지역에서 투자할 수 있는 것을 확인하실 수 있습니다. 곧도 레벨에 도달하고 브레인 컨설턴트가 되시면 더 많은 지역들에서 시뮬레이션을 돌려보실 수 있습니다.

컨설턴트 레벨에서 지원되는 지역으로는 아시아(ASI), 유럽(EUR), 한국(KOR), 대만(TWN), 홍콩(HKG), 일본(JPN), 아메리카(AMR), 그리고 모든 지역들의 주식을 한 번에 시뮬레이션할 수 있도록 통합한 글로벌(GLB) 등이 있습니다.

Universe

유니버스는 지역 내에 몇 개의 주식을 대상으로 시뮬레이션을 할지를 규정하는 옵션입니다.

예컨대 미국에는 **TOP N**개의 주식을 대상으로 하는 유니버스들을 선택 가능한 것을 보실 수 있는데요, 거래량을 기준으로 **N**개의 주식을 대상으로 시뮬레이션을 진행하겠다는 것입니다.

중국에서는 **2000**개의 주식을 대상으로 하는 유니버스에서 시뮬레이션을 진행하실 수 있습니다.

DELAY

Delay는 얼마만큼 지연된 데이터를 쓸 것인지를 결정할 수 있는 옵션입니다. 오늘 들어온 데이터를 오늘 바로 쓰는 것은 생각보다 쉽지 않은 일입니다. 알파 표현식을 계산하는 데도 시간이 걸리고, 데이터가 들어오는 시간이 조금 지연이 될 수도 있죠.

예컨대 종가를 생각해보는다면, 종가는 하루의 주식시장이 끝나기 전까지는 알 수 없습니다. 이러한 제약 때문에, 보통은 하루의 지연이 있는, 즉 어제까지 쌓인 데이터를 이용하는 **Delay1** 알파를 만드는 것이 보편적입니다.

하지만 시장의 변화를 더 빠르게 반영하고 싶으시다면 **Delay0** 알파를 만들어보시는 것도 좋은 생각입니다. 그러나 **Delay0** 알파는 제약이 많기 때문에 더 엄격한 조건을 갖춰야 제출할 수 있습니다.

Delay0에서는 Delay1과 이름이 같은 데이터필드이더라도 그 값은 다를 수 있습니다. 위에서 말씀드린 close라는 종가 데이터는 Delay1에서는 종가 그대로를 쓰지만, Delay0에서는 장 마감되기 조금 전 가격을 중간값과 위에서 사용하고 있습니다.

Neutralization

알파를 만들다 보면, 알파가 구성하는 포지션이 특정 산업에 편향이 될 때가 자주 있습니다. 예컨대 어제 유가가 상승해서 석유화학 관련주들이 모두 일제히 상승하고, 석유를 연료로 쓰는 항공산업 관련주는 일제히 하락했다고 생각해보겠습니다.

이런 상황에서는 rank(-returns)라는 모멘텀의 반대로 움직 수익추적 전략이라도 한쪽으로 치우칠 수 있습니다. 항공사와 관련주들 순위가 아래쪽에 올 것입니다. 앞서 우리가 살펴 본 시장리스크에 노출된 상황과 마찬가지로, 이 알파는 산업 리스크에 노출되게 된 것입니다.

시장리스크는 같은 크기의 롱포지션과 숏포지션을 가져가는 방식으로 헷지(hedge)하였는데요, 산업리스크는 어떻게 헷지할 수 있을까요?

시장리스크를 헷지할 때와 마찬가지로, 중립화를 진행해주는 방식으로 헷지할 수 있습니다. 단, 모든 주식에 대해서 중립화를 진행하는 것이 아니라, 같은 산업 내에 있는 기업들 내에서만 중립화를 진행하는 것이죠.

이렇게 하면 석유화학 관련주들 중에서도 적게 오른 주식들에 롱포지션을, 많이 오른 주식들에는 숏포지션을 걸고갈 수 있습니다. 마찬가지로 항공 관련주들 중에서 많이 내린 주식들에는 롱포지션을, 적게 내린 주식들에는 숏포지션을 걸고가게 되죠.

Decay

Decay는 과거의 포지션을 얼마만큼 반영할 것인가를 설정할 수 있는 세팅입니다. 앞서 자세히 살펴보았는데요, Decay의 값이 높을수록 알파의 턴오버가 낮아지고, 트레이딩이 줄어들게 됩니다. 하지만 정보가 늦어지는 만큼 알파의 샤프 비율이 낮아질 수 있다는 점을 유의해야 합니다.

Truncation

알파를 만들다보면 특정 종목이 나머지 포지션에 물리게 되는 경우가 있을 수 있습니다. 이런 상황에서 Truncation을 사용할 수 있는데요, Truncation은 하나의 종목이 가질 수 있는 비중의 최대값을 제한해주는 옵션입니다. TOP3000 유니버스에서는 0.01(1%) 정도의 값을 사용하는 것이 통상적입니다. 하지만 TOP200과 같이 작은 유니버스에서는 최대로 갖고가는 포지션을 조금 더 크게 갖고가는 것이 더 좋을 수 있습니다.



Pasteurization, Unit Handling, NaN Handling

이 세 가지 옵션은 처음부터 사용하기는 조금 어려운 개념인데요, 간단히 말씀드리면 다음과 같습니다.

- **Pasteurization**은 유니버스에 포함되지 않는 종목들을 계산에 포함시킬지, 아니면 NaN으로 둘지를 결정하는 옵션입니다.

- **Unit Handling**은 데이터필드의 단위가 맞지 않는 경우를 감지하여 시뮬레이션 시에 경고해주는 기능입니다. 실제 시뮬레이션에 영향을 미치지 않는 경고만 나타내주기 때문에 **Verify** 하나의 옵션만 제공됩니다.
- **NaN Handling**은 데이터필드에 결측치(NaN)가 있을 때 이를 0으로 대체할지 선택하는 옵션입니다.

Let's try out!

자유롭게 세팅을 설정하여 알파를 작성하고 시뮬레이션해보세요. 알파의 내용과 관계 없이 시뮬레이션이 완료되면 다음 스텝으로 넘어갈 수 있습니다.

원하는 알파를 자유롭게 시뮬레이션하고 결과를 확인해보세요.

힌트: 원하는 알파를 자유롭게 시뮬레이션하고 결과를 확인해보세요. 예시답안: `vwap/close`

Finding Datafields

BRAIN에서 데이터를 활용하는 법

브레인 플랫폼에서는 금융 시장의 데이터를 미리 정해진 이름으로 쉽게 불러올 수 있는데요, 이번 스텝에서는 원하는 데이터를 어떻게 찾는지에 관해서 알아보도록 하겠습니다. 먼저 플랫폼 내에서 데이터를 분류하는 방법을 살펴보겠습니다.

- 데이터셋 카테고리
- 데이터셋
- 데이터필드

데이터셋 카테고리

데이터셋 카테고리는 데이터를 분류에 따라 총 **16**가지의 대분류로 나눠놓은 것입니다. 플랫폼 화면 상단에 "**Data**"를 클릭하시면 데이터셋 카테고리에 해당하는 분류들을 확인할 수 있습니다. (컨설턴트가 되기 전에는 **7**개의 카테고리만 표시됩니다.) 대표적으로는 기업의 재무제표에 기록된 데이터인 **Fundamental**, 주식의 가격과 거래량과 관련된 데이터인 **PV** 등이 있습니다.

데이터셋

데이터셋은 같은 주제를 가진 데이터들을 모아놓은 것입니다. 보통은 데이터셋 카테고리의 이름에 숫자를 붙여서 나타내게 되는데요, 예컨대 **PV1** 데이터는 주식시장 내의 가격/거래량과 관련된 데이터셋으로 시가, 고가, 저가, 종가와 같은 가격 정보와 **20**일 간의 평균 거래량 같은 정보도 포함하고 있습니다. **fundamental6** 데이터셋은 재무제표에 기록되어있는 기업의 자산, 자본, 부채 등의 데이터를 폭넓게 제공하고 있습니다.

데이터필드

데이터필드는 실제로 플랫폼에서 쓰게 되는 행렬 형태의 데이터인데요, 데이터필드의 이름을 통해서 시뮬레이터에서 데이터필드 내의 내용을 불러올 수 있습니다. 앞서 이용한 **returns**라는 데이터도, 수익률 정보를 담은 **returns**라는 데이터필드를 불러오게 된 것입니다.

원하는 데이터 찾기 ([데이터 탐색기](#))

브레인에서는 데이터 탐색기로 원하는 데이터필드를 쉽게 찾을 수 있도록 지원하고 있습니다. 데이터셋이나 데이터필드의 이름을 검색하여 찾을 수도 있고, 카테고리에서부터 탐색하면서 찾아들어갈 수도 있습니다.

리전과 유니버스에 따라서 사용할 수 있는 데이터필드들이 다르니, 검색하기 전에 우측 상단에서 원하는 리전과 딜레이, 유니버스를 설정하는 것을 잊지 마세요!

 **Let's try out!**

이번에는 데이터 네비게이터를 활용하여, 앞서 이용한 **returns**를 제외한 데이터필드를 이용해 시뮬레이션을 돌려보도록 하겠습니다. 자유롭게 원하는 데이터를 찾아서 만들어보고 싶은 알파를 시뮬레이션해보세요.

returns를 제외한 데이터필드를 이용해 알파를 시뮬레이션해보세요.

힌트: 데이터필드는 화면 상단 **Data**를 클릭하셔서 탐색하실 수 있습니다. 또한 시뮬레이터에 앞부분을 입력하면 데이터필드를 자동완성 해주기도 합니다.

예시답안: **vwap/close**

Finding Operators

BRAIN에서 오퍼레이터 활용하기 ([link](#))

앞서 **-returns**에 ****rank()**를 적용하여 행렬 내의 값을 바꾼 것처럼, 오퍼레이터를 통해 데이터필드 내 행렬에 변형을 가할 수 있습니다. BRAIN에서는 사칙연산을 비롯한 간단한 연산을 비롯하여 다양한 오퍼레이터를 제공하고 있습니다.

Arithmetic Operators

산술 연산자는 사칙연산과 더불어 반올림 등 산술적인 연산을 할 수 있도록 하는 연산들입니다.

Logical Operators

논리 연산자는 참과 거짓을 판별해주는 연산자입니다. 브레인 플랫폼에서는 참이면 1, 거짓이면 0의 값을 갖게 됩니다.

Time Series Operators

시계열 연산자는 특정 종목과 관련하여 과거의 d일의 값과 관련된 연산을 해 주는 연산자들입니다. 예컨대 `ts_mean(x,d)`는 d일 간의 x의 평균을 구해줍니다.

Cross Sectional Operators

횡단면 연산자는 특정 시점에 대상 종목들의 값을 비교 또는 처리해주는 연산자입니다. 예컨대 `rank(x)`는 특정 시점의 x의 순서를 구하여 0부터 1까지의 값으로 분배해줍니다.

Vector Operators

알파 탐색을 위해 데이터필드를 찾다 보면, 벡터 타입의 데이터필드를 보실 수 있습니다. 이는 하루 한 종목에 하나의 값이 저장된 행렬이 아니라, 여러개의 값(벡터 형식)이 저장되어있는 데이터 형식인데요, 이를 알파 포지션으로 변환하기 위해서는 평균이나 중앙값 등 여러개의 값을 대표할 수 있는 하나의 값으로 바꾸어 주어야 합니다. 이를 위한 연산자라고 할 수 있습니다.

Transformational Operators

변환 연산자는 행렬 내의 값을 특정한 연산을 거쳐 변환할 수 있도록 하는 연산자입니다.

Group Operators

알파 탐색을 위해 데이터필드를 찾다 보면, 그룹 타입의 데이터필드를 보실 수 있는데요, 그룹 데이터필드는 특정 기준에 의해 기업들을 그룹으로 묶어놓은 데이터필드입니다. 예컨대 `industry`라는 데이터필드는 산업별로 기업들을 분류하는 그룹 데이터필드입니다.

그룹 오퍼레이터는 이러한 그룹을 이용해 평균/합/중앙값 등의 대표값을 구하거나 그룹 내에서 중립화를 하는 등의 연산을 포함하고 있습니다.

🌟 Special Operators

특정 분류에 들어가기 어려운 오퍼레이터들은 **Special Operator**들로 따로 분류되어 있습니다.

🔥 Let's try out!

이번에는 타임시리즈 오퍼레이터 중 하나를 활용하여, 시뮬레이션을 돌려보도록 하겠습니다. 자유롭게 원하는 데이터를 찾아서 만들어보고 싶은 알파를 시뮬레이션해보세요.

Time Series 오퍼레이터를 이용하여 알파를 시뮬레이션해보세요.

힌트: 화면 상단 **Learn**을 클릭하신 후 **Operator**에 들어가 보시면 쓸 수 있는 오퍼레이터를 확인하실 수 있습니다. 종류별로 나뉘져 있으며 **Time Series** 오퍼레이터도 모여서 정리되어 있습니다. 시계열 오퍼레이터의 대부분은 **ts_**으로 시작합니다.

예시답안: `-ts_returns(close,5)`

About Price Volume alpha


📈 PV 데이터를 이용한 알파

플랫폼 익히시느라 고생 많으셨습니다 🙌 그러면 이제 본격적으로 어떤 알파를 만들 수 있는지에 대해 살펴보도록 하겠습니다 😊

PV 데이터는 가격과 거래량과 관련된 정보들을 담고 있는 데이터입니다. 아무래도 주가를 예측하는데 가격 그 자체를 포함하는 데이터이기 때문에, 처음 알파를 만들 때는 가장 접근성이 좋은 데이터 중 하나입니다.

💰 Price data

PV 데이터에는 주식시장의 가격 정보가 포함되는데요, 하루의 가격을 설명하는 데이터는 크게 네 개가 있습니다. 이 값들은 캔들차트에 잘 나타나 있습니다.



- ****시가(open)****는 하루의 주식시장이 시작될 때 첫번째로 거래된 가격입니다.
- ****종가(close)****는 하루의 주식시장이 마무리될 때 마지막으로 거래되는 가격입니다.
- ****고가(high)****는 하루 중 가장 높은 가격으로 거래되었을 때의 가격입니다.
- ****저가(low)****는 하루 중 가장 낮은 가격으로 거래되었을 때의 가격입니다.

📦 Volume

****거래량(volume)****은 그 날 몇 개의 주식이 거래되었는가를 나타내는 값입니다.

adv20이라는 데이터필드를 통해서 20일간의 거래량의 평균을 이용할 수 있습니다. 다른 N일의 평균을 구하고 싶으시다면 ****ts_mean(volume,N)****을 이용하실 수 있습니다.

📈 VWAP (Volume-Weighted Average Price)

추가적으로, **VWAP**이라는 가격도 하루의 주가를 대표할 수 있는데요, 이는 거래량으로 가중평균한 가격을 의미합니다. 종가를 비롯한 다른 가격 지표들은 거래량이 적은 특정 거래 때문에 가격이 왜곡되어 보일 수 있기 때문에, **VWAP**이 그 날의 가격을 더 잘 보여주는 수치가 될 수 있습니다. 다음의 표를 보실까요?

Price	Volume
10	100
11	120
12	80
13	10
VWAP	11

여기에서 **VWAP**으로 들어가는 이 11이라는 가격은, 거래된 양과 가격을 곱한 것의 합에서 총 거래된 양의 합으로 나눠준 것입니다. 이를 수식으로 나타내면 $\text{sum}(\text{price} \times \text{volume}) / \text{sum}(\text{volume})$ 이 되죠.

Alpha Idea

PV 데이터를 이용한 알파는 크게 다음의 두 가지 아이디어에서 나오는 것이 대부분입니다.

- 모멘텀(**Momentum**) - 상승하던 주식은 계속 상승하고, 하락하던 주식은 계속 하락하는 경향
 - 모멘텀 효과는 주로 장기적(수 개월 이상)인 기간에 걸쳐 관찰됩니다.
- 리버전(**Reversion**) - 급등한 주식은 하락하고, 급락한 주식은 상승하여 평균으로 회귀하는 경향
 - 리버전 효과는 단기적(며칠, 몇 주)인 기간 동안 관찰됩니다.

맨 처음에 만들었던 ****rank(-returns)****도 리버전 효과를 아주 간단하게 만들어 본 예시라고 할 수 있습니다.

Let's try out!

VWAP을 이용해서 리버전 알파의 아이디어를 한 번 구현해 볼까요? **VWAP**은 하루의 거래량 평균 가격이고, 종가는 하루의 마지막에 거래된 가격입니다. 따라서 **VWAP**과 종가를 비교하면, 마지막에 거래된 가격이 하루의 평균에 비해 어떤 상태에 있는지 알 수 있는 것이죠. 예컨대 종가가 **VWAP**보다 많이 높다면, 장의 마지막에 잠깐동안 가격이 급격하게 상승한 것이라고 해석해 볼 수 있습니다. 그 반대도 마찬가지겠죠.

리버전은 가격이 원래대로 회귀한다는 가설이기 때문에, *****vwap/close*****라는 수식을 통해서 종가가 **vwap**에 비해 낮은 경우는 롱포지션을, 반대의 경우에는 숏포지션을 가져가는 알파를 구현할 수 있습니다.

시뮬레이션해보시면 확인하실 수 있지만, **Sharpe**비율은 높는데 반해 턴오버가 지나치게 높은 것을 확인할 수 있습니다. 브레인 플랫폼의 제출 기준 상 턴오버는 **70%** 이하가 되어야 제출할 수 있는데요, 오퍼레이터를 적용하거나 세팅을 변경해가면서 턴오버를 조절할 수 있습니다. 다음의 조건을 만족하는 알파를 시뮬레이션해보도록 하겠습니다.

vwap/close를 포함하고, 턴오버는 **70%** 이하인 알파를 시뮬레이션해보세요.

힌트: **vwap/close**을 포함하는 알파를 시뮬레이션해보세요. **Decay, trade_when** 등 다양한 방법을 통해서 알파의 턴오버를 컨트롤할 수 있습니다.

예시답안: **# DECAY 10**

vwap/close

About Close Location Value



기술적 분석의 이해

****기술적 분석(Technical Analysis)****은 주가와 거래량의 과거 데이터를 바탕으로 미래의 가격 움직임을 예측하는 분석 방법입니다. 이는 시장 참여자들의 심리와 행동 패턴이 반복된다는 가정에 기반하며, 차트 패턴, 가격 추세, 모멘텀 지표, 이동평균선 등 다양한 지표들을 활용합니다. 이를 통해서 시장의 비효율성을 포착하고 수익을 창출하는데 이용하겠다는 것이지요. 대표적으로는 다음과 같은 지표들이 있으니, 알파 탐색에 활용해보세요.

- **RSI (Relative Strength Index):** 주가의 상승/하락 정도를 나타내는 모멘텀 지표
- **볼린저 밴드 (Bollinger Bands):** 이동평균선을 중심으로 표준편차를 이용해 상/하한 밴드를 설정
- **MACD (Moving Average Convergence Divergence):** 단기와 장기 이동평균선의 차이를 이용한 추세 지표



CLV를 이용한 알파

알파를 만들 때 쉽게 이용할 수 있는 기술적 지표 중의 하나로 **CLV**가 있습니다.

****CLV(Close Location Value)****는 하루 동안의 가격 변동 범위에서 종가가 어디에 위치하는지를 나타내는 지표입니다. 이는 앞선 **vwap/close**와 마찬가지로, 당일의 가격 움직임에서 마지막 순간의 시장 심리를 파악할 수 있게 해주는 지표라고 할 수 있습니다.



CLV 계산 방법

CLV는 다음과 같은 공식으로 계산됩니다:

$$CLV = ((\text{종가} - \text{저가}) - (\text{고가} - \text{종가})) / (\text{고가} - \text{저가})$$

CLV 값은 **1**에서 **-1**까지의 값을 갖는데요, 각 값의 특징은 다음과 같습니다:

- CLV가 **1**에 가까울수록 종가가 고가에 가깝다는 의미
- CLV가 **-1**에 가까울수록 종가가 저가에 가깝다는 의미



Alpha Idea

CLV는 하루(단기적 기간)의 가격 변화를 잡아내는 지표입니다. 따라서 모멘텀/리버전이라는 **PV**의 두가지 큰 갈래 중 리버전 알파를 만드는 데 더 적합한 지표가 될 수 있습니다. 따라서 다음과 같은 알파가 유효할 수 있습니다.

CLV가 낮을 때 (**-1**에 가까울 때) → 매수 포지션

CLV가 높을 때 (**1**에 가까울 때) → 매도 포지션

CLV와 거래량의 조합

CLV는 **거래량(volume)**과 함께 사용하면 더 의미있는 시그널이 만들어질 수도 있습니다:

Let's try out!

CLV와 **거래량(volume)**을 이용해서 Sharpe가 1.4 이상인 알파를 만들어보세요. CLV는 변형하여 사용하실 수 있으니, **high, low, close, volume** 이렇게 네 가지 데이터필드를 모두 활용한 알파를 통과 기준으로 두어보도록 하겠습니다.

high, low, close, volume 네 가지 데이터필드를 모두 활용하여 Sharpe가 1.4 이상인 알파를 만들어보세요.

힌트: clv 표현식은 -1부터 1까지의 값을 갖는 지표입니다. 거래량이 많을 수록 더 많은 포지션을 할당하는 함수를 작성해 보세요.

예시답안:

```
# DECAY 0
```

```
clv = ((close-low)-(high-close))/(high-low);
```

```
-clv*rank(volume)
```

About Momentum Effect



모멘텀 효과의 이해

모멘텀 효과(Momentum Effect)는 금융시장에서 자주 관찰되는 현상으로, 최근 상승한 자산은 계속 상승하고 하락한 자산은 계속 하락하는 경향을 보이는 것을 의미합니다. 모멘텀 효과는 여러 학술 연구를 통해 그 존재가 입증되고 있습니다.



모멘텀 효과의 특징

모멘텀 전략은 시간 관점에 따라 다르게 나타납니다:

- 단기(1개월 미만): 리버전 효과가 더 강하게 나타남
- 중기(3-12개월): 전통적인 모멘텀 효과가 가장 뚜렷함
- 장기(12개월 이상): 효과가 점차 약화되는 경향



BRAIN에서 모멘텀 효과 구현해보기

모멘텀 효과는 다양한 방법으로 구현할 수 있습니다. 가장 쉬운 방법으로는 최근까지의 가격 상승분을 계산하는 방법이 있습니다. 자산의 1년 간의 가격 상승분을 계산해볼까요? 브레인에서 하루는 영업일만을 생각하기 때문에, 1년의 길이는 통상 1년 내의 영업일 수인 252일로 나타냅니다. 1년 간의 가격 변화를 나타내기 위해, 시계열 오퍼레이터인 `ts_returns(close,252)` 를 통해서 x의 변화량을 측정할 수 있죠.

하지만 이 수식을 사용하게 될 경우, 좋은 결과의 알파가 나타나지는 않습니다. 1년간의 수익률은 최근 기간의 수익률에도 크게 영향을 받게 되는데, 이렇게 되면 단기적 관점에서 리버전 효과의 영향을 받게 되기 때문이죠. 브레인에서 모멘텀 효과를 알파로 구현하기 위해서는 다른 방법을 사용하거나, 조건을 붙여주어야 합니다.



BRAIN에서 모멘텀 효과를 구현하는 다양한 방법

그렇기 때문에 모멘텀 효과를 더 명확히 보기 위해서는 다음의 방법들을 이용할 수 있습니다.

- 1년간 수익률에 딜레이를 주어 단기적 리버전 효과 완화
 - `ts_delay(ts_returns(close,252),10)`
- 1년간 상승한 날짜의 수를 카운트
 - `ts_sum(returns>0? 1:0, 252)`

1년간 상승한 날짜의 수를 카운트하여 알파에 이용해보세요.

`positive_days = ts_sum(returns>0? 1:0, 252);` 이런 식으로 변수에 할당하고 쓸 수도 있습니다.

- `<condition>? <if_true>:<if_false>` 는 특정 조건을 만족했을 때는 `if_true`의 값을, 아닐 때는 `if_false`의 값을 갖도록 합니다. `if_else(<condition>,<if_true>,<if_false>)` 도 똑같은 의미를 갖습니다.

힌트: 설명에 따라 차근차근 **positive days**를 만들어 보세요.

예시답안: `ts_sum(returns>0? 1:0, 252)`

About Logical Operators

⚡ 알파에 조건 이용하기

알파를 만들 때, 조건을 이용하여 알파의 포지션을 세부적으로 조정할 수 있습니다. 조건은 **if_else()** 오퍼레이터나 **trade_when()** 오퍼레이터 등을 통해서 이용하실 수 있습니다.

🎨 조건 만들기

일반적으로 널리 사용되는 논리 연산자들(>, <, >=, <=, == 등)을 통해서 쉽게 조건을 만들 수 있습니다. 예컨대 거래량이 평소(20일 간의 평균)보다 많을 때만 거래하기를 원한다면, **volume > adv20** 으로 조건을 설정할 수 있는 겁니다. 다음의 조건들을 생각해 볼 수 있는데, 이외에도 원하는 조건을 작성해서 자유롭게 이용하실 수 있습니다. 조건을 너무 까다롭게 설정하게 되면, 데이터포인트의 수가 줄어들어 오버피팅의 위험이 증가한다는 점에 유의할 필요도 있습니다.

- 거래량이 평소보다 많을 때만 거래
- 특정 값이 극단적인 상황에서 포지션 청산
- 변동성이 높은 구간에서는 거래 제한

✂ if_else(condition, if_true, if_false)

알파를 구현할 때 특정 조건에 따라 다른 값을 반환해야 하는 경우가 있습니다. **if_else** 연산자는 이러한 조건부 로직을 간단하게 구현할 수 있게 해주는 기본적인면서도 강력한 오퍼레이터입니다.

if_else는 **condition? if_true:if_false** 의 형태로도 사용할 수 있는데요, 앞서 살펴본 **ts_sum(returns>0? 1:0, 252)** 안의 **returns>0? 1:0, 252** 도 이러한 형태를 활용한 예시 중 하나입니다.

🎯 trade_when(entry_condition, alpha, exit_condition)

trade_when 연산자를 이용하면 알파 내에서 언제 값을 변경할지를 결정할 수 있습니다. **trade_when** 연산자는 특정 조건에서만 알파값을 변경하고, 그 외의 경우에는 이전 포지션을 유지하도록 합니다.

trade_when은 세가지 입력값을 받는데요, 순서대로 진입조건, 알파식, 청산조건입니다.

- 진입조건이 참일 때는 날마다 알파식의 값을 갱신합니다.
- 청산조건이 참일 때는 포지션을 청산합니다.(NaN)
- 둘 다 거짓일 때는 알파식의 값을 갱신하지 않습니다. (마지막으로 진입조건이 참이었을 때의 알파값 유지)

청산조건에 **-1**을 입력할 경우, 따로 포지션 청산이 일어나지 않습니다.

💡 모멘텀 알파에 **trade_when** 활용해보기

앞서서 모멘텀 알파를 만들기 위해 1년간 상승한 날짜의 수를 카운트한 `ts_sum(returns>0? 1:0, 252)` 를 살펴보았습니다. 여기에 거래 조건을 설정하기 위해서는, `positive_days = ts_sum(returns>0? 1:0, 252);` 로 수식을 저장하고, `trade_when`의 두번째 인풋에 넣어보는 방법을 활용할 수 있습니다.

진입 조건을 설정해 볼까요? 거래량이 급증할 때 각 주식들은 모멘텀을 타게 되고, 따라서 알파의 성과도 좋아질 거라는 가설으로 조건을 설정해보겠습니다. 조금씩 다르기는 하지만, 다음의 방법들로 거래량의 급증을 포착할 수 있습니다.

- `volume > adv20 * N` #adv20: 거래량의 20일 평균
- `volume > ts_mean(volume, N_DAYS) * N`
- `volume * vwap > ts_mean(volume * vwap, N_DAYS) * N`

`N_DAYS`와 `N`은 원하는 숫자로 넣어서 테스트해보실 수 있습니다.

모멘텀 효과는 장기적인 효과이기 때문에, 한 번 포지션이 바뀌면 오래 동일 포지션을 유지할 수 있도록 청산조건에 `-1`을 넣어주는 것이 효과적입니다.

또한 모멘텀 효과는 산업 내 보다는 여러 산업에 걸쳐 일어나는 경향이 있으므로 **Neutralization** 옵션은 너무 세부적인 그룹으로 나누지 않게 설정하는 것이 좋을 수 있습니다.

`trade_when`과 `positive_days`를 이용하여 알파를 만들어 보세요.

힌트: `positive days`는 조건과 함께할 때 더 잘 작동합니다. 거래량과 관련한 조건을 붙여보세요.

예시답안: `positive_days=ts_sum(returns>0? 1:0, 252);`
`trade_when(volume>adv20*5,positive_days,-1)`

About Alpha Submit Criteria

✓ 알파 제출 기준

알파는 일정한 기준을 통과해야 브레인 알파 풀에 "제출"이 가능한데요, 알파에는 성능 검증이 필요하기 때문입니다. 브레인 플랫폼에서는 다양한 테스트를 통과해야 알파를 제출할 수 있습니다.

이번에는 USA 리전의 Delay1 알파의 제출 기준에 대해서 알아보텐데요, 리전과 Delay에 따라서 제출 기준은 조금씩 달라집니다. 제출 기준 설명 페이지에서 각 리전과 Delay에 따른 제출 기준을 상세히 보실 수 있습니다.

📊 주요 성능 지표 (USA D1 알파)

알파 제출을 위해서는 주요 성능지표에서 다음 기준을 통과해야 합니다.

- **Fitness:** 1.0 이상
- **Sharpe:** 1.25 이상
- **Turnover:** 1%이상 70% 이하
- **Weight:** 단일 종목 최대 비중 10% 미만

🛡️ 견고성 테스트

알파의 안정성을 확인하기 위한 추가 검증들입니다:

- **서브유니버스 테스트:** 더 유동성이 높은 주식들만을 대상으로 하는 작은 유니버스에서도 일정 수준의 성과가 유지되어야 합니다.
- **Self-Correlation** 테스트: 기존에 제출한 모든 알파와의 상관관계가 0.7 미만이어야 합니다.
- **지역별 추가 테스트:** 중국 시장은 더 높은 기준이 적용되고, 거래의 어려움 때문에 추가적으로 통과해야하는 테스트들이 있습니다.

🔥 Let's try out!

이제 지금까지 배운 내용들을 종합하여 **Self-Correlation**을 제외한 모든 기준을 만족하는 알파를 만들어보도록 하세요. 좋은 알파라고 생각되면, 그대로 제출하셔도 좋습니다. 하지만 이미 제출하고 나면, 상관계수가 0.7 이상인 비슷한 알파를 제출할 수 없으니 신중하게 제출하시기를 권해드립니다. 성과를 개선할 수 있다면 제일 좋은 성과를 보이는 알파를 제출하시는 것이 좋습니다.

또한 하루에 2,000점의 점수만 획득할 수 있습니다. 알파 하나 당 1,000점~2,000점 정도의 점수를 얻을 수 있는데요, 골드 레벨을 달성하기 위한 10,000점에 도달하기 위해서는 5일에 걸쳐 알파를 제출해야 합니다. 하루에 획득 가능한 최대 점수를 잘 고려하여 제출해주세요.

제출 가능한 알파를 만들어보세요!

힌트: 지금까지 배운 것들을 찬찬히 짚어보며 제출 가능한 알파를 만들어 보세요.

예시답안:

```
# SUBINDUSTRY, DECAY: 10, TRUNCATION 0.08
```

```
clv = ((close-low)-(high-close))/(high-low);
```

```
rank(rank(ts_mean(volume,60)/ts_mean(volume,252))*rank(-clv))
```

또는

```
#MARKET, DECAY 0, TRUNCATION 0.01
```

```
positive_days=ts_sum(returns>0? 1:0, 252);
```

```
trade_when(volumeewap>ts_mean(volumeewap,252)*5,positive_days,-1)
```

About Fundamental Data

기업 펀더멘털 데이터의 이해

펀더멘털 데이터에 대해 알아보도록 하겠습니다 😊 기업의 펀더멘탈이라고 하는 것은 투자자들이 기업의 본질적 가치를 평가하는데 사용하는 정보인데요, 이 데이터는 보통 기업의 재무제표를 기반으로 하고 투자 의사결정에 핵심적인 역할을 합니다.

데이터 출처

기업의 펀더멘털 데이터는 주로 세 가지 주요 재무제표에서 추출됩니다:

- 재무상태표(Balance Sheet): 기업의 자산, 부채, 자본 현황
- 손익계산서(Income Statement): 매출, 비용, 이익 정보
- 현금흐름표(Cash Flow Statement): 실제 현금 유출입 현황

데이터 업데이트 주기

펀더멘털 데이터는 다음과 같은 특징을 가집니다:

- 분기별, 반기별, 연간 단위로 업데이트되기 때문에, 턴오버가 낮은 특징을 가집니다.
- 상장 거래소와 기업 규모에 따라 공시 주기가 다릅니다.
- PV 데이터와 달리 불연속적으로 업데이트될 수도 있습니다.

데이터의 의미 및 필요성

펀더멘털 데이터는 다음과 같은 의미를 갖습니다:

- 펀더멘털 데이터를 통해서 기업의 실제 사업 현황을 객관적으로 파악할 수 있습니다.
- 기업의 미래 성장 가능성을 예측하는 기초 자료로 사용될 수 있고, 기업가치 평가의 핵심 요소가 됩니다.

Let's try out!

가장 대표적으로 활용할 수 있는 펀더멘털 데이터로는 ****자산(assets), 자본(equity), 부채(debt)****가 있는데요, 이 세가지 데이터필드 중 하나 이상을 자유롭게 사용하여 펀더멘털 데이터가 어떤 느낌인지에 대해서 감을 잡아보도록 하겠습니다.

assets, equity, debt 중 하나 이상의 데이터필드를 이용해서 알파를 시뮬레이션해보세요.

힌트: **assets, equity, debt** 중 하나 이상의 데이터필드를 이용해서 알파를 시뮬레이션해보세요.

예시답안: **equity/assets**

About Combining PV and Fundamental Data

가격-펀더멘털 결합 알파 만들기

PV(Price-Volume) 데이터와 펀더멘털 데이터를 결합하면 더욱 의미있는 알파를 만들 수 있습니다. 이번에는 PV 데이터 중 하나인 시가총액(**cap**)과 펀더멘털 데이터 중 하나인 영업이익(**operating_income**)을 결합하여 기업의 수익성 순위를 활용하는 알파를 살펴보도록 하겠습니다.

데이터의 특징

두 데이터는 서로 다른 특징을 갖는데요, 알파를 만들기에 앞서 미리 두 데이터 간의 특징에 대해 짚어보겠습니다.

펀더멘털 데이터인 영업이익(**operating_income**)은 다음과 같은 특징을 갖고 있습니다.

- 분기/연간 단위로 업데이트
- 기업의 실제 수익창출 능력 반영
- 비즈니스의 효율성 측정

PV 데이터인 시가총액(**cap**)은 다음과 같은 특징을 갖고 있습니다.

- 시장에서 평가하는 기업 가치
- 일별로 업데이트
- 주가와 발행주식수의 곱

알파 아이디어

시가총액은 현재 시장에서 해당 기업이 얼마만큼의 가치를 평가받고 있느냐를 나타냅니다. 똑같은 사업을 해서 똑같은 양의 수익성을 내는 기업들도 미래에 대한 기대(보유 기술, 뉴스에 따른 전망 등의 영향을 받을 수 있습니다.)에 따라 시가총액은 달라질 수 있습니다.

영업이익은 실제로 기업이 기록한 해당 분기의 이익을 나타냅니다. 따라서 시가총액과 영업이익을 비교하면, 미래에 대한 기대에 비해 현재 기업이 기록하고 있는 성적을 확인해 볼 수 있습니다.

두 데이터 비교하기

어떻게 이 둘을 비교해 볼 수 있을까요? 비교하는 방법에는 여러가지가 있지만, 가장 대표적이고 쉬운 방법으로는 빼서 차이를 구하거나 나눠서 비율을 구하는 방법이 있습니다. 상황에 따라 적절한 방법은 달라질 수 있습니다.

■ 뺄셈이 더 적절한 경우

예컨대 애널리스트의 전망과 실제 기업의 실적을 비교할 때는 얼마만큼의 차이가 나는지 확인해야하기 때문에, 뺄셈(subtract)로 차이를 구하는 것이 적절한 방법이 될 수 있습니다.

➗ 나눗셈이 더 적절한 경우

하지만 시가총액과 영업이익은 직접적으로 같은 규모(scale)를 갖는 수치가 아니기 때문에, 나눠줌으로써 영업이익이 시가총액에 비해 몇 %의 크기를 갖고 있는지 비율을 확인하는 것이 더 적절한 방법이 될 수 있습니다.

또한 뺄셈을 이용할 경우 기업의 규모에 따라서도 값의 크기에 차이가 날 수 있기 때문에, 항상 데이터의 규모와 단위에 대해서도 신경을 써 주어야 합니다.

💬 데이터를 비교할 수 있는 또 다른 방법

단순한 뺄셈과 나눗셈 이외에도, 다양한 방법으로 데이터를 비교할 수 있습니다. 예컨대 $(y-x)/x$ 는 두 데이터 x, y 를 비율로 비교합니다.

🔥 Let's try out!

영업이익(operating_income) 과 시가총액(cap) 을 이용하여 알파를 만들어보겠습니다. 원하는 비교 방법을 이용해서 알파를 만들어보세요.

처음에는 시그널이 원하는 만큼 나오지 않을 수 있습니다. 하지만 걱정하지 마세요! 다음 스텝에서 이를 개선시키는 방법을 배워보도록 하겠습니다.

원하는 비교 방식으로 영업이익(operating_income) 과 시가총액(cap) 을 이용하여 알파를 만들어 보세요.

힌트: operating_income을 cap으로 나눠보세요.

예시답안: operating_income/cap

About Combining PV and Fundamental Data (2)

가격-펀더멘털 결합 알파 만들기: **EBITDA/Enterprise Value**

PV(가격-거래량) 데이터와 펀더멘털 데이터를 결합하면 더욱 의미있는 알파를 만들 수 있습니다. 이번에는 기업 가치 평가 지표를 활용하여 기업가치(**Enterprise Value**)라는 PV 관련 지표와 **EBITDA**라는 펀더멘털 데이터 포인트를 결합한 알파를 살펴보도록 하겠습니다.

데이터의 특징

두 데이터는 서로 다른 특징을 갖는데요, 알파를 만들기에 앞서 미리 두 데이터 간의 특징에 대해 짚어보겠습니다.

펀더멘털 데이터인 **EBITDA** (이자, 세금, 감가상각, 무형자산상각 차감전 영업이익) 은 다음과 같은 특징을 갖고 있습니다:

- 분기/연간 단위로 업데이트
- 기업의 전반적인 재무성과를 측정
- 영업 수익성에 대한 명확한 그림을 제공
- 자본구조나 세율이 다른 기업들을 비교할 때 유용

PV 데이터인 기업가치(**Enterprise Value, EV**) 는 다음과 같은 특징을 갖고 있습니다:

- 기업의 총 가치를 나타냄
- 시가총액에 부채, 소수주주지분, 우선주를 더하고 현금 및 현금성자산을 차감하여 계산
- 주가 변동에 따라 자주 업데이트됨
- 시가총액과 달리 기업의 부채와 현금 포지션을 고려함

알파 아이디어

기업가치는 부채를 포함한 시장이 기업에 부여하는 총 가치를 보여주며, **EBITDA**는 영업활동에서 발생하는 기업의 수익력을 나타냅니다. 이 둘을 비교함으로써, 기업이 수익 창출 능력 대비 저평가되었는지 혹은 고평가되었는지 평가할 수 있습니다.

두 데이터 비교하기

이러한 지표들을 비교하는 가장 일반적인 방법은 **EV/EBITDA** 비율을 계산하는 것입니다. 이는 흔히 "기업가치 배수"라고 불립니다.

+ 나눗셈이 적절한 이유

나뉘셈이 여기서 특히 적합한 이유는:

- 서로 다른 규모의 기업들을 비교할 수 있게 해줌
- 금융분석에서 널리 사용되는 표준화된 지표(기업가치 배수)를 만들어냄
- 기업의 **EBITDA**로 기업가치를 상환하는 데 걸리는 연수를 측정할 수 있음



비율 해석하기

- 낮은 **EV/EBITDA** 비율은 기업이 저평가되었을 수 있음을 시사
- 높은 비율은 고평가 또는 높은 성장 기대치를 나타낼 수 있음
- 산업별 비교가 중요함, 일반적인 비율은 섹터별로 크게 다를 수 있음

앞서 살펴본 **EBITDA/EV**와 영업이익/시가총액은 모두 기업가치 대비 수익성을 비교하며, 운영 성과에 초점을 맞춥니다. 이들은 주가가 자주 업데이트되는 분모를 가진 기업과 산업 간 상대적 가치 평가에 사용됩니다. 비슷하지만, **EBITDA/EV**가 더 포괄적인 것으로 간주되는데, 이는 부채와 비현금성 비용을 고려하기 때문입니다.

수익성(영업이익, **EBITDA** 등)과 규모(시가총액, 기업가치 등)를 나타내는 값이 다를 수 있다는 점을 유념하세요.



Let's try out!

****기업가치(enterprise value)****와 **EBITDA**를 이용하여 알파를 만들어보세요.
원하는 비교 방법을 이용해서 알파를 만들어보세요. 가장 직관적인 접근법은 각 기업의 **EV/EBITDA**를 계산하고 순위를 매기는 것입니다. 낮은 값이 잠재적으로 더 매력적인 투자 기회를 나타낼 수 있습니다.

About TS & CS Operators

오퍼레이터의 종류: 시계열 & 횡단면

앞서 오퍼레이터들을 살펴보면서 오퍼레이터의 종류가 여럿 있다는 것을 확인했습니다. 이번 스텝에서는 특정 값을 살펴보는 두 가지 방법에 대해서 알아볼 텐데요, 시계열(**Time Series**) 방식과 횡단면(**Cross-Sectional**) 방식입니다.

시계열(**Time Series**) 오퍼레이터

학교에서 시험을 본 학생이 이번에 80점의 점수를 받았다고 생각해보겠습니다. 이 학생의 점수를 평가하는 방법에는 크게 두 가지가 있을 수 있을 텐데요, 하나는 과거 자신의 점수와 비교해 보는 것이고, 나머지 하나는 다른 친구들의 이번 시험 점수와 비교해 보는 것입니다.

원래 항상 70점을 받아왔는데, 이번에 처음으로 80점에 도달한 것이면 충분히 좋은 성적을 거둔 것이라 할 수 있겠죠? 시계열(**Time Series**) 오퍼레이터는 이렇게 과거 자신의 점수와 비교해 보는 첫번째 방법에 비유될 수 있습니다. 또한, 과거의 값들을 가져와서 평균(**ts_mean**)을 구하거나 변화량(**ts_delta**)을 구하는 오퍼레이터도 시계열 연산자에 포함됩니다.

시계열(**Time Series**) 오퍼레이터에는 대표적으로 다음의 오퍼레이터들이 있습니다.

- **ts_rank(x,d)**: 지난 d일 동안의 각 종목별 x값을 순위화하고, **rank()**와 동일하게 0~1까지의 스케일로 분배해줍니다.
- **ts_zscore(x,d)**: 오늘의 x가 d일 간의 평균으로부터 얼마나 떨어져있는지를 표준편차 단위로 나타낸(**Z-score**) 값입니다.
- **ts_mean(x, d)**: 과거 d일 간 x값의 평균을 반환합니다.
- **ts_returns(x,d)**: 과거 d일 간 x값의 상대적인 변화율을 반환합니다.

횡단면(**Cross-Sectional**) 오퍼레이터

80점의 점수를 받은 학생의 주변 친구들은 이번 시험에서 90점 정도를 받았다고 생각해봅시다. 친구들과 비교하는 측면에서 생각해보면 그렇게 훌륭한 성적을 거뒀다고 말하기는 어렵겠죠?

이처럼 횡단면(**Cross-Sectional**) 오퍼레이터는 다른 친구들의 이번 시험 점수와 비교하는 두 번째 방법에 비유해볼 수 있습니다.

횡단면(**Cross-Sectional**) 오퍼레이터에는 대표적으로 다음의 오퍼레이터들이 있습니다.

- **rank(x)**: 모든 종목들 중 해당 입력값의 순위를 매겨서 0.0에서 1.0 사이의 균등 분포된 값으로 반환합니다.
- **zscore(x)**: 해당 instrument의 x값이 평균으로부터 얼마나 떨어져있는지를 표준편차 단위로 나타낸(**Z-score**) 값입니다.
- **regression_neut(y, x)**: 주식들에 대해 Y를 종속변수, X를 독립변수로 하여 횡단면 회귀분석을 수행합니다.

- **winsorize(x, std=4)**: x의 모든 값들이 표준편차의 배수로 지정된 상한값과 하한값 사이에 들어오도록 winsorize(극단값 제한)를 수행합니다.

그림으로 이해하기

다음의 그림을 통해 이해해보도록 하겠습니다. 2020년 1월 10일에 Company1을 기준으로 연산을 한다고 한다면, 빨간색으로 표시된 부분은 시계열 연산에 사용되는 부분이 됩니다. 반면 초록색으로 표시된 부분은 횡단면 연산에 사용되는 부분이 되는 것입니다.

	COMPANY1	COMPANY2	COMPANY3	COMPANY4
1/6/2020	70			
1/7/2020	70			
1/8/2020	70			
1/9/2020	70			
1/10/2020	80	90	91	89
1/11/2020				

상황에 맞는 오퍼레이터 고르기

알파를 구현할 때, 상황에 따라 더 적절한 오퍼레이터가 달라질 수 있습니다. 각 기업마다 규모(sclae)이 달라 횡단면적으로 비교하기 힘든 경우에는 시계열 오퍼레이터가 더 적절한 경우가 있을 수 있습니다. 하지만 모델 데이터의 경우는 이미 이를 다 고려하여 기업마다의 수치를 부여한 경우가 있을 수 있습니다. 이런 경우에는 횡단면 오퍼레이터가 더 적절할 수 있습니다.

보통은 과거에서 현재까지 기업의 변화에 따라 주가가 변하는 경우가 많기 때문에, 시계열 오퍼레이터가 더 잘 작동하는 경우가 많습니다. 하지만 데이터에 따라 그렇지 않은 경우도 있기 때문에, 어떤 비교 방식이 더 적절한지는 시뮬레이션을 반복해가면서 탐색해보시는 것을 추천드립니다.

Let's try out!

앞서 **operating_income**과 **cap**을 비교하는 방법을 살펴보았습니다. 이 두 수치를 비교하는 대표적인 방법은 나눠주는(divide) 것인데요, **operating income**을 **cap**으로 나눠주는 이 지표는 **Operating Earnings Yield (OEY)** 라는 이름으로 기업의 수익성을 평가하는 데 널리 쓰이고 있습니다.

그리고 이 **OEY**라는 수치는 시계열 오퍼레이터에서 더 좋은 성과를 보이는 경향이 있습니다. **OEY**에 **ts_rank(oey, N_DAYS)** 를 이용해서 결과를 확인해보세요. **OEY**는 업데이트 주기가 분기로 긴 간격을 갖는 값이기 때문에, **N_DAYS**에 반년(126) 또는 1년(252) 등 중장기적인 값을 넣어보시는 것을 추천드립니다.

OEY를 **ts_rank()** 로 비교하는 알파를 만들어서 시뮬레이션해보세요.

힌트: OEY에 **ts_rank()**를 적용해보세요.

예시답안: `ts_rank(operating_income/cap,252)`

About Universe

Across the Universe

BRAIN에서는 거래량을 기준으로 TOP3000부터 TOP200까지 다양한 유니버스를 선택하실 수 있습니다. 각 유니버스는 서로 다른 특성을 가지고 있는데요, 알파의 성능이 여러 유니버스에서 일관되게 나타난다면 이는 매우 견고한 알파라고 할 수 있습니다.

유니버스의 구조

유니버스의 숫자가 작을수록 더 유동성(**liquidity**)이 높고, 높은 시가총액을 가진 주식들로만 유니버스가 구성됩니다. 따라서 “작은 유니버스” 라고 하는 것은 보통 덩치가 크고 거래가 잘 되는 기업들로만 구성된 유니버스를 의미한다고 볼 수 있습니다.

통상적으로 유동성이 높아진다는 것은 거래가 많이 일어난다는 것이고, 주식시장에서 정보의 반영이 그만큼 빠르게 된다는 것을 의미하는데요, 그렇기 때문에 작은 유니버스에서는 상대적으로 알파의 시그널이 잘 안나오는 경우가 많습니다.

Subuniverse Test

앞서 제출 기준에서 **Subuniverse Test**가 있다는 것을 확인했는데요, 이 테스트는 더 작은 유니버스에서도 알파의 시그널이 유지가 되는지를 확인하는 테스트입니다. 더 거래량이 많고 시그널이 나오기 힘든 유니버스에서도 잘 작동할 수 있는 알파인지를 확인함으로써, 알파의 거래 가능성을 파악하고 더불어 강건성(**robustness**)을 테스트하는 것입니다. 만약 이 테스트를 통과하지 못한다면, 해당 알파는 거래량이 적은 주식들에서만 수익을 내기 때문에 실제로 거래를 하기는 어려운 알파일 가능성이 높습니다. 이런 경우 거래량이 높고 시가총액이 큰 주식에 포지션을 더 집중하게 하여 거래를 용이하게 한다면 **Subuniverse Sharpe**를 개선시킬 수 있습니다.

Let's try out!

앞서 만든 **ts_rank(OEY, N_DAYS)** 는 작은 유니버스에서도 상당히 잘 작동하는 좋은 알파가 될 수 있습니다. 유니버스가 달라지면 **Correlation**도 낮아지는 경우가 많기 때문에, 알파 제출의 측면에서 다양성을 늘려줄 수 있다는 장점이 있습니다. 다양한 유니버스에서 시뮬레이션해보면서 알파의 성과를 확인해보세요.

ts_rank(OEY, N_DAYS) 를 TOP1000, TOP500, TOP200 등 다양한 유니버스에서 시뮬레이션해보세요.

힌트: OEY에 **ts_rank()**를 적용하고, TOP3000이 아닌 유니버스에서 시뮬레이션해보세요.

예시답안:

TOP500

ts_rank(operating_income/cap,252)

Summary

펀더멘탈 데이터

펀더멘탈 데이터는 기업의 실제 재무성과를 보여주는 중요한 지표입니다.

PV(Price-Volume) 데이터와 결합하면 더욱 의미 있는 알파를 만들 수 있습니다.

알파 탐색 전략

데이터를 비교하고 싶을 때는 다음의 방법을 활용할 수 있습니다.

- 뺄셈(**subtract**) 또는 나눗셈(**divide**) 활용: 지표를 간단하게 비교하고 싶을 시 적합
- $(y-x)/x$ 등 다양한 방법으로도 비교할 수 있음

분석 방법

- 시계열(**Time Series**): 과거 대비 현재 성과 비교
- 횡단면(**Cross-Sectional**): 다른 기업들과의 비교

추천 지표: Operating Earnings Yield (OEY)

$oe_y = \text{operating_income} / \text{cap};$

$ts_rank(oe_y, N_DAYS)$

권장 사항

- 유니버스 크기에 따른 성과 차이 고려
- 장기 시계열(126일 또는 252일 이상) 사용 권장

Let's try out!

펀더멘탈 데이터에 대해 배운 내용을 바탕으로 제출 가능한 본인의 알파를 탐색해 보세요.

하루에 2,000점의 챌린지 점수만 획득할 수 있습니다. 알파 하나 당 1,000점~2,000점 정도의 점수를 얻을 수 있는데요, 골드 레벨을 달성하기 위한 10,000점에 도달하기 위해서는 5일에 걸쳐 알파를 제출해야 합니다. 하루에 획득 가능한 최대 점수를 잘 고려하여 제출해주세요.

제출 가능한 알파를 만들어보세요!

다른 유니버스에서도 같은 수식을 시뮬레이션해서 제출 가능한지도 확인해보세요 ☺

힌트: 지금까지 배운 것들을 찬찬히 짚어보며 제출 가능한 알파를 만들어 보세요.

예시답안:

```
#TOP500 SUBINDUSTRY DECAY 0 TRUNCATION 0.01
```

```
ts_rank(operating_income/cap,252)
```

#이 예시는 TOP1000과 TOP200에서도 잘 작동합니다.

About Option Alpha

옵션(Option)의 기초

? 옵션이란?

옵션은 미래 특정 시점에 특정 가격으로 주식을 살 권리 또는 팔 권리를 의미합니다. 의무가 아닌 권리가기 때문에, 옵션을 소유한 사람은 옵션의 만기가 되었을 때 해당 주식을 사거나 팔지 않아도 된다는 특징이 있습니다. 옵션을 갖기 위해 지불하는 금액을 옵션 프리미엄이라고 하는데요, 쉽게 말하면 옵션 프리미엄은 옵션의 가격이라고 할 수 있습니다.

옵션은 시장 참여자들의 심리를 나타내는 좋은 지표이기 때문에 알파 시그널을 탐색하는데도 유용하게 사용될 수 있습니다. 알파 탐색에 옵션 데이터를 이용하기 위해, 미리 필요한 지식들을 간단하게 배워보도록 하겠습니다.

옵션의 두 가지 종류

위에서 옵션은 살 수 있는 권리와 팔 수 있는 권리로 나뉘었다고 했는데요, 살 수 있는 권리를 콜옵션(Call Option) 이라고 하고, 팔 수 있는 권리는 풋옵션(Put Option) 이라고 합니다.

콜옵션 (Call Option)

콜옵션은 정해진 가격에 어떤 자산을 살 수 있는 권리입니다.

예컨대 A 기업의 주가가 현재 6만원인데 일주일 뒤에도 똑같은 6만원에 사고 싶다면, 옵션 프리미엄을 지불하고 다음주가 만기인 A 기업 6만원 콜옵션을 사면 되는 것입니다. 만약 A 기업의 주가가 만기 시점에 7만원으로 오른다면, 만원 만큼의 이익을 보면서 주식을 살 수 있겠죠? 이렇게 되면 만기가 가까워지면서 콜옵션 자체의 가격도 크게 오르면서 이익을 보게 될 것입니다.

그렇기 때문에, 콜옵션은 자산의 가격이 오를 것이라는 데 베팅(롱포지션)하는 용도로도 살 수 있습니다.

풋옵션 (Put Option)

풋옵션은 정해진 가격에 어떤 자산을 팔 수 있는 권리입니다.

풋옵션은 콜옵션이랑 반대되는 권리라고 생각하면 좋은데요, 콜옵션과는 반대로 자산의 가격이 내릴 것이라는 데 베팅(숏포지션)하는 용도로 살 수 있습니다.

주요 용어

- 행사가격(Strike Price): 미래에 사거나 팔기로 약속한 가격
- 손익분기점 가격(Breakeven Price): 옵션 거래에서 손실도 이익도 발생하지 않는 지점
- 만기(Expiration): 권리를 행사할 수 있는 마지막 날짜

- 프리미엄(Premium): 옵션의 가격(구매 비용)
- 변동성(Volatility): 주가 변동성을 나타내는 지표
 - Historical Volatility: 과거 실제 가격 변동성
 - Implied Volatility: 옵션 가격에서 역산한 미래 예상 변동성

옵션에서의 변동성

변동성은 옵션의 가격에 큰 영향을 미치는 요소입니다. 주가의 변동성이 크면 그만큼 옵션으로 위험을 헤지하거나 가격변동에 베팅하려는 수요가 많아지기 때문에, 옵션의 가격이 올라가게 됩니다. 변동성은 크게 **Historical Volatility**와 **Implied Volatility**로 나눌 수 있습니다.

- **Historical Volatility**는 과거 실제 가격 데이터를 기반으로 계산되는 변동성으로, 주로 일일 수익률의 표준편차를 연율화하여 계산하는 후행지표입니다.
- **Implied Volatility**는 현재 시장에서 거래되는 옵션 가격에 내재된 변동성으로, 블랙숄즈 모형 등을 통해 역산출되며 시장 참여자들의 미래에 대한 예측을 반영하는 선행지표입니다. 옵션의 가격에 따라서 내재변동성이 계산되기 때문에, 옵션의 가격을 나타내는 또 다른 지표로도 생각해 볼 수 있습니다.

Historical Volatility는 기존의 주가에서 나오는 변동성이라면, **Implied Volatility**는 옵션가에서 계산되는 변동성이라고 할 수 있는데요, 이 두 변동성을 비교하여 옵션 또는 주식의 고평가/저평가 여부를 판단하는 데 활용할 수 있습니다.

Let's try out!

이번 스텝에서는 내재변동성을 이용해서 알파를 만들어보도록 하겠습니다. 내재변동성은 **implied_volatility_{call/put}_{만기}** 라는 이름의 데이터필드로 불러올 수 있습니다. 내재변동성과 관련한 알파 아이디어에는 다음의 아이디어들이 있습니다.

- 풋/콜 옵션의 내재변동성 비교
- 내재변동성과 역사적 변동성 간의 차이 비교
- 내재변동성의 추이 비교

자유롭게 내재변동성(implied_volatility_~)을 이용한 알파를 만들어보세요!

힌트: implied_volatility_call_120, implied_volatility_put_180 등 옵션 종류와 만기를 붙여 그에 해당하는 데이터필드를 불러올 수 있습니다.

예시답안: `ts_rank(implied_volatility_call_120,20)`

About Option Alpha

옵션 시장의 특징

옵션 거래는 레버리지가 크고 방향성, 변동성, 시간가치 등 다양한 요소가 복합적으로 작용하기 때문에 더 신중하게 많은 정보를 바탕으로 접근해야 합니다. 그렇기 때문에 일반적으로 옵션 트레이더들은 주식을 거래하는 시장 참여자보다 더 많은 정보를 갖고 거래를 한다고 알려져 있습니다. 따라서 콜옵션과 풋옵션의 수요에 차이가 생긴다면, 이것은 미래 주가의 방향성을 예측하는 데 도움이 될 수 있다는 것입니다.

풋옵션과 콜옵션의 내재변동성은 각 옵션의 가격을 반영

풋-콜 내재변동성 차이 분석

앞서 옵션의 내재변동성은 옵션의 가격, 즉 수요를 반영하고 있는 지표라는 것을 살펴보았습니다. 옵션의 가격이 높으면 내재변동성이 커지고, 가격이 낮아지면 내재변동성이 작아지게 되죠. 따라서 풋옵션과 콜옵션의 내재변동성의 차이를 살펴보면 각 옵션의 수요의 차이를 짐작해 볼 수 있습니다.

- 콜옵션이 풋옵션보다 내재변동성이 큰 경우: 옵션 트레이더들은 주식의 가격이 상승할 것으로 전망
- 풋옵션이 콜옵션보다 내재변동성이 큰 경우: 옵션 트레이더들은 주식의 가격이 하락할 것으로 전망

풋-콜 내재변동성 비교하기

풋옵션과 콜옵션의 내재변동성은 어떻게 비교하는 것이 좋을까요? 내재변동성은 기본적으로 모든 주식에 대해 같은 스케일로 계산됩니다. 풋과 콜 여부에 따라서 내재변동성의 스케일이 다르지도 않기 때문에, 기본적으로 뺄셈(-)을 이용하는 것이 가장 직관적일 수 있습니다. 그러나 상황에 따라 나눗셈(/)이나 회귀(regression_neut) 등 원하는 계산 방법을 이용해보실 수도 있습니다.

Let's try out!

이번에는 풋옵션과 콜옵션의 내재변동성 차이를 이용하여 알파를 만들어보도록 하겠습니다. 두 값의 차이를 포함한 알파를 만들어보세요.

iv_difference =
{comparison_operator}(implied_volatility_call_{만기},implied_volatility_put_{만기});

과 같이 변수에 할당하여 이용하실 수도 있습니다.

콜옵션의 내재변동성(implied_volatility_call_{만기})과 풋옵션의 내재변동성(implied_volatility_put_{만기})을 비교하는 알파를 만들어보세요!

힌트: $\text{implied_volatility_call_120} - \text{implied_volatility_put_120}$ 와 같이 되도록 같은 만기 조건에서 비교하는 것이 더 정확한 비교입니다.

예시답안:

$\text{implied_volatility_call_120} - \text{implied_volatility_put_120}$

또는

$\text{implied_volatility_call_120} / \text{implied_volatility_put_120}$ 등

About Neutralization

중립화란?

중립화(Neutralization)는 특정 요인(factor)의 영향을 제거하거나 최소화하여 순수한 전략의 성과를 얻고자 하는 기법입니다. 중립화를 통해서 특정 알파에서 원하지 않는 팩터의 영향을 감소시킬 (또는 제거할) 수 있습니다. 통상적으로 중립화를 진행하게 되면 샤프는 증가하고, 리턴 또는 마진은 감소하는 경향이 있습니다.

브레인 플랫폼에서는 다음의 방법으로 중립화를 구현할 수 있습니다.

- 그룹 중립화 (Group Neutralize)
- 회귀 중립화 (Regression Neutralize)
- 벡터 중립화 (Vector Neutralize)

그룹 중립화 (Group Neutralize)

그룹 중립화는 그룹을 나눠서 그 안에서만 표준화를 해 주는 것입니다. 가장 대표적인 예시로는 Settings에서 설정 가능한 산업별 중립화가 있습니다. 산업별로 그룹을 나누고 그 안에서 표준화를 해 준다면 산업에 의한 알파의 성과는 중립화하고 시뮬레이션을 할 수 있습니다.

Settings에서 산업 중립화를 하는 것 외에도, 브레인 플랫폼에서는 여러 그룹 데이터와 `group_neutralize` 오퍼레이터를 이용해서 그룹 중립화를 할 수 있습니다.

Group Datafields

`**group_neutralize(x,group)**`의 두 번째 입력값은 그룹 데이터를 입력할 수 있게 해줍니다. 그룹 데이터 필드는 특정 기준에 따라 각 종목을 분류하는 데이터입니다. **sector, industry, subindustry** 등 settings에서 찾을 수 있는 다양한 데이터 필드를 사용할 수 있으며, 필요에 따라 추가 데이터 필드도 `exchange`에서 찾을 수 있습니다. Price Volume Data for Equity와 Relationship Data for Equity에서 유용한 데이터 필드를 찾아보세요.

Bucket() 연산자

아이디어에 맞는 적절한 기존 그룹이 없다면 아래와 같이 **bucket** 연산자를 사용하여 직접 만들 수 있습니다:

```
bucket(X, range="{start},{end},{step}")
```

예를 들어, 시가총액 크기에 따라 10개 그룹으로 나누고 싶다면

`bucket(rank(cap), range="0,1,0.1")`을 사용하여 `rank(cap)` 값에 따라 0 ~ 0.1, 0.1 ~ 0.2, ..., 0.9~1.0 이렇게 10개의 그룹을 만들 수 있습니다.

Densify() 연산자

그룹 데이터필드 사용 시 과도한 연산으로 인한 시뮬레이션 실패가 발생할 수 있습니다. 이는 그룹 데이터필드의 값이 희소 분포될 때 발생하여 연산이 비효율적이 됩니다. 이런 경우 그룹 데이터필드에 **densify()** 연산자를 적용하면 문제 해결에 도움이 될 수 있습니다. 자세한 내용은 Operator Explorer의 **densify()** 설명을 참고하세요.

Let's try out!

앞서 만든 풋옵션과 콜옵션의 내재변동성 차이를 그룹 중립화해보는 알파를 만들어보도록 하겠습니다. 먼저 **iv_difference**에 다음의 수식을 할당하겠습니다.

```
iv_difference = implied_volatility_call_{만기} - implied_volatility_put_{만기};
```

내재변동성의 차이는 주식이 가진 변동성 자체에 영향을 받을 수 있습니다. 원래 주가의 변동성이 크다면 내재변동성의 차이도 클 것이기 때문에, 주식의 변동성을 중립화 해 줄 경우 조금 더 순수한 옵션의 수요 차이를 캐치해낼 수 있을 거라는 가설을 세워볼 수 있습니다. **std_group**이라는 이름으로 변동성의 그룹을 만들어봅시다. 그룹의 턴오버가 너무 높지 않도록 기간에는 **120**이나 **180** 등 중장기적인 기간을 쓰는 것을 권장합니다.

```
std_group = bucket(rank(historical_volatility_{기간}),range="0.1,1,0.1");
```

이제 그룹으로 그룹 중립화를 진행해봅시다.

```
group_neutralize(iv_difference,std_group)
```

이를 모두 포함하여 알파를 만들어 보세요!

힌트: **bucket()**을 이용하여 **rank(historical_volatility_120)**로 그룹을 만들어 사용해보세요.

예시답안:

```
iv_difference = implied_volatility_call_120 - implied_volatility_put_120;  
std_group = bucket(rank(historical_volatility_120),range='0.1,1,0.1');  
group_neutralize(iv_difference,std_group)
```


About Double Neutralization

✌ 이중 중립화란?

이중 중립화는 그룹 중립화에서 사용할 수 있는 방법인데요, 두 개의 서로 다른 그룹 특성을 동시에 중립화하는 고급 기법입니다. 단순히 두 번의 중립화를 순차적으로 적용하는 것이 아닌, 두 특성을 결합한 새로운 그룹을 생성하여 한 번에 중립화합니다.

👉 이중 중립화 구현하는 법

이중 중립화의 핵심은 두 그룹의 특성을 하나의 새로운 그룹으로 결합하는 것입니다. 그룹에는 그룹의 개수만큼 숫자 라벨이 붙게 되는데요, 예컨대 **industry**는 첫번째 산업에 0, 두번째 산업에는 1, ... 이런 식으로 숫자가 붙는 모양입니다. 이런 특성을 이용하여, 다음의 방법으로 두 그룹을 하나의 그룹으로 교차하여 만들 수 있습니다.

$$\text{최종_그룹} = \text{그룹1} \times \text{그룹2의_최대값} + \text{그룹2}$$

예컨대 각각 10개의 그룹이 있는 그룹1과 그룹2를 생각해 봅시다. 이렇게 되면 두 그룹은 각각 0~9의 숫자 라벨이 있게 됩니다. 최종 그룹이 $\text{그룹1} \times 10 + \text{그룹2}$ 이 된다면, 0부터 99까지 총 100개의 그룹으로 나뉘게 됩니다. 어떤 주식이 그룹1에서는 3번 그룹에 속하고, 그룹2에서는 5번 그룹에 속한다면, 최종 그룹에서는 35번 그룹에 속하게 되는 것이죠.

📋 주의할 점

이중 중립화를 적용할 때 가장 흔히 하는 실수는 두 개의 **group_neutralize** 연산자를 순차적으로 적용하는 것입니다. **group_neutralize(group_neutralize(alpha, industry), country)** 와 같은 방식은 두 번째 중립화가 첫 번째 중립화의 효과를 부분적으로 상쇄시키기 때문에 바람직하지 않습니다. 대신 앞서 설명한 방식으로 두 그룹을 결합한 후 한 번의 중립화를 수행해야 합니다.

또한 너무 많은 그룹이 생겨서 그룹 하나 당 주식 개수가 너무 적어지는 경우를 조심해야 할 필요가 있습니다. 예컨대 위에서 해본 것처럼 100개의 그룹이 있는 최종 그룹은 총 200개의 주식밖에 없는 TOP200 유니버스에서는 사용하기 어렵습니다. 그룹 하나에 너무 적은 주식이 들어가면 알파가 적합하게 피팅되지 않거나 오버피팅될 위험이 있기 때문입니다.

🔥 Let's try out!

앞선 스텝에서 두 개의 변수를 만들어서 알파에 활용해 보았습니다.

```
iv_difference = implied_volatility_call_{만기} - implied_volatility_put_{만기};
```

```
std_group = bucket(rank(historical_volatility_{기간}),range="0.1,1,0.1");
```

std_group에 더해서, 지난 5일 간의 수익률을 바탕으로 returns_group이라는 그룹을 만들어 보겠습니다.

```
returns_group = bucket(rank(ts_returns(close,5)),range="0.1,1,0.1");
```

최종 그룹(**final_group**) 을 만들기 위해, 이중 중립화의 방법을 사용해보겠습니다.

```
final_group = std_group * 10 + returns_group;
```

이제 최종 그룹으로 그룹 중립화를 진행하면 이중 중립화를 할 수 있습니다.

```
group_neutralize(iv_difference,final_group)
```

이를 모두 포함하여 알파를 시뮬레이션해 보세요!

힌트: `implied_volatility_call_120 - implied_volatility_put_120` 와 같이 되도록 같은 만기 조건에서 비교하는 것이 더 적절한 비교입니다. 예시답안: `iv_difference = implied_volatility_call_120 - implied_volatility_put_120; std_group = bucket(rank(historical_volatility_120),range='0.1,1,0.1'); returns_group = bucket(rank(ts_returns(close,5)),range='0.1,1,0.1'); final_group = std_group*10 + returns_group; group_neutralize(iv_difference,final_group)`

Summary

옵션(Option)의 기본 개념

1. 옵션의 정의와 종류

- 옵션: 미래 특정 시점에 특정 가격으로 주식을 사거나 팔 수 있는 권리
- 콜옵션: 살 수 있는 권리 (주가 상승 예상 시 활용)
- 풋옵션: 팔 수 있는 권리 (주가 하락 예상 시 활용)
- 옵션 프리미엄: 옵션의 구매 비용

2. 주요 용어

- 행사가격: 약속된 매매 가격
- 만기: 권리 행사 마지막 날짜
- 변동성: 주가 변동 지표
- **Historical Volatility**: 과거 실제 변동성
- **Implied Volatility**: 옵션가격 기반 예상 변동성

3. 옵션 시장의 특징

- 옵션 트레이더들은 일반적으로 더 많은 정보 보유
- 풋-콜 내재변동성 비교로 시장 전망 파악 가능
- 콜옵션 IV > 풋옵션 IV: 상승 전망
- 풋옵션 IV > 콜옵션 IV: 하락 전망

중립화(Neutralization) 기법

- 특정 요인의 영향 제거/최소화하기 위해 사용하는 기법
- 그룹 중립화: 그룹별 표준화
- 회귀 중립화: 회귀분석 통한 영향 제거
- 벡터 중립화: 벡터 정사영 이용
- 이중 중립화: 두 그룹 특성 동시 중립화
 - 최종그룹 = 그룹1 × 그룹2의_최대값 + 그룹2

Let's try out!

옵션 데이터와 중립화에 대해 배운 내용을 바탕으로 제출 가능한 본인의 알파를 탐색해 보세요.

하루에 2,000점의 챌린지 점수만 획득할 수 있습니다. 알파 하나 당 1,000점~2,000점 정도의 점수를 얻을 수 있는데요, 골드 레벨을 달성하기 위한 10,000점에 도달하기 위해서는 5일에 걸쳐 알파를 제출해야 합니다. 하루에 획득 가능한 최대 점수를 잘 고려하여 제출해주세요.

제출 가능한 알파를 만들어보세요!

힌트: 지금까지 배운 것들을 찬찬히 짚어보며 제출 가능한 알파를 만들어 보세요. 예시답안:

```
#MARKET DECAY4 TRUNCATION 0.08 iv_difference = implied_volatility_call_120 -  
implied_volatility_put_120; std_group =  
bucket(rank(historical_volatility_120),range=0.1,1,0.1'); returns_group =  
bucket(rank(ts_returns(close,5)),range='0.1,1,0.1'); final_group = std_group*10 +  
returns_group; group_neutralize(iv_difference,final_group)
```

About Sentiment Alpha

❤️ 센티먼트 알파

센티먼트(**Sentiment**)는 특정 주식에 대한 시장의 집단적인 심리나 분위기를 나타냅니다. 이는 신문, 뉴스 웹사이트, 소셜 미디어(페이스북, 트위터), 블로그, 토론방 등 다양한 온라인 플랫폼에서 수집된 데이터를 기반으로 합니다. 이러한 투자자들의 심리는 주가 움직임의 선행지표가 될 수 있습니다.

브레인에서는 센티먼트와 소셜미디어 데이터를 제공하고 있는데요, 이는 여러 출처 또는 SNS에서 기업이 언급될 때 부정적인지/긍정적인지를 자연어 분석 처리를 통해서 수치화하고 이를 기록한 데이터필드들입니다.

📡 거래량 기반 센티먼트 전략

거래량과 센티먼트의 관계를 활용하면 잘 작동하는 시그널을 찾을 수 있습니다. 특정 주식이 거래량에 비해 인터넷 공간상에서 비정상적으로 많은 언급이 되고 있다면, 이는 해당 기업의 주가가 하락 또는 상승할 것이라는 신호일 수 있다는 가설을 세워볼 수 있습니다. 이러한 가설의 배경에는 과도한 관심이 종종 과열/저평가의 신호가 될 수 있다는 통찰이 있습니다.

🔥 Let's try out!

sc12_buzz는 센티먼트의 양을 수치화한 데이터필드입니다. 이는 인터넷 상에서 각 주식에 대한 언급 자체가 얼마나 많이 되고 있는가를 나타냅니다. 거래량(**volume**)에 비해 센티먼트의 양이 얼마나 되는지 비교하는 방법은 앞서 많이 살펴보았듯이 다양할 수 있는데요, 이번 케이스에서는 ****ts_regression(y, x, lookback_days)****를 통해서 비교하는 것이 가장 효과적인 방법입니다. **regression_neut**를 이용하여 두 데이터필드를 비교해보세요. 생각했던 것과 방향이 다르다면 알파의 앞에 -를 붙여서 PnL의 개형을 뒤집을 수 있습니다.

ts_regression를 활용하여 **sc12_buzz**와 **volume** 두 데이터필드를 비교하는 알파를 시뮬레이션해보세요.

힌트: **ts_regression(y,x,lookback_days)**에서 **sc12_buzz**는 **y**이고 **volume**은 **x**여야 합니다. 예시 답안: **ts_regression(-sc12_buzz,volume,252)**

힌트: **volume**에 비한 상대적인 **sc12_buzz**의 크기를 파악하기 위해서는, **regression_neut(y,x)**에서 **sc12_buzz**가 **y**가 되고 **volume**이 **x**가 되어야 합니다. 예시답안: **regression_neut(-sc12_buzz,volume)**

About News Alpha

뉴스 데이터셋 개요

BRAIN의 뉴스 데이터는 시장의 움직임에 영향을 주는 금융 뉴스를 양적으로 가공하여 제공합니다. 뉴스 데이터는 여러 출처에서 수집되는데요, 다음 출처에서 최신 금융 뉴스를 가져옵니다:

- 재무 보고서 (실적, 투자, 배당)
- 애널리스트 추천 (전망, 등급, 의견)
- 기업 제품 (신제품, 승인)
- 법적 이벤트 (조사, 파산)

뉴스는 주가에 영향을 미치는 만큼 가격-거래량 데이터와 함께 이용될 때 효과적인 시그널을 얻을 수 있습니다.

거래 세션

미국 주식 시장은 세 개의 세션으로 나뉩니다:

1. **Pre session:** 4:00 am to 9:30 am
2. **Main session:** 9:30 am to 4:00 pm
3. **Post session:** 4:00 pm to 8:00 pm

뉴스는 일반적으로 장전 및 장후 세션에 공개됩니다.

벡터 데이터 필드

Vector 데이터는 종목당 하루 이벤트 수가 고정되지 않은 데이터 필드입니다. 예컨대 한 기업에 대한 뉴스는 하루에도 여러개가 있을 수 있으니, 이를 벡터 형식으로 저장해 두는 것이죠. **Matrix** 데이터가 종목당 하루에 하나의 값을 가지는 것과 달리, **Vector** 데이터는 한 칸에 여러 값을 저장하여 더 자세한 정보를 담을 수 있습니다.

알파 표현식을 작성할 때, 결과는 시장 포지션을 나타내는 알파 값의 행렬이 됩니다. 플랫폼 연산자는 행렬 입력을 위해 설계되었으므로, **Matrix** 연산자를 적용하기 전에 **vec_~** 연산자를 사용하여 벡터 데이터를 행렬 형태로 변환해야 합니다. **vec_~** 오퍼레이터를 적용하면 아래 그림과 같이 각 날짜와 종목에 대한 벡터 데이터를 하나의 값으로 집계하여 이루어집니다.

알파 아이디어

nws12_afterhsz_si 데이터 필드는 각 뉴스 발표 이후에 롱 포지션과 숏 포지션 중 어느 것이 더 유리할지를 나타냅니다. 이 정보는 벡터형 필드에 저장되며, 기업은 여러 개의 뉴스 정보를 가질 수 있습니다. 롱 포지션이 유리했던 뉴스 이벤트가 더 많은 주식은 강한 모멘텀을 보일 수 있으며, 그러한 이벤트가 적은 기업은 리버전을 보일 수 있습니다.

간단히 말해서, 이 접근법은 모멘텀과 리버전 알파 아이디어를 결합합니다. 특정 조건(롱 포지션이 유리했던 뉴스 이벤트가 더 많은 경우) 하에서 알파는 모멘텀 효과를 적용하고,

그렇지 않은 경우에는 반전 시그널을 사용합니다. 이 아이디어의 표현은 다음과 같이 보일 수 있습니다:

<condition: 더 많은 롱 포지션이 유리했던 뉴스 이벤트>?<모멘텀 시그널(롱 포지션)>:<리버전 시그널(숏 포지션)>

구현

롱 포지션이 유리했던 뉴스 이벤트가 더 많은 주식을 식별하는 것부터 시작해보겠습니다. **nws12_afterhsz_si**는 날마다 한 기업이 여러 개의 값을 가지고 있으므로, **vec_avg** 연산자를 사용하여 이를 하나의 대표값으로 나타낼 수 있습니다.

- ****vec_avg(nws12_afterhsz_si)****는 기업의 전반적인 뉴스センチメント가 긍정적인지 부정적인지를 나타냅니다.

이 일일 데이터의 노이즈를 줄이고 더 명확한 시그널을 추출하기 위해, 적절한 기간을 가진 시계열 연산자(**ts_sum**이나 **ts_mean**)를 적용하세요.

- 일일 데이터의 노이즈를 줄이기 위해 적절한 기간의 시계열 연산자를 적용하세요. **ts_sum**이나 **ts_mean**이 이 목적에 잘 맞습니다.
- 데이터를 **Rank**하고 임계값을 설정하세요. 예를 들어, 주식의 절반을 **True**로, 나머지를 **False**로 분류하려면 **rank(X) > 0.5**와 같은 조건을 사용하세요.

조건을 설정한 후, PV 알파 섹션에서 배운 대로 모멘텀과 반전 시그널을 설정하세요. 다음 사항을 명심하세요:

- ****vec_avg(nws12_afterhsz_si)****를 기반으로 한 조건은 이미 모멘텀을 포함합니다. 조건을 충족하는 주식에 대해 단순히 롱 포지션(상수 1 사용)을 취하는 것이 모멘텀 시그널이 될 수 있습니다.
- 의도한 전략에 맞게 모멘텀 시그널과 반전 시그널의 규모를 신중하게 조절하세요.

Let's try out!

nws12_afterhsz_si는 각 뉴스 발표 이후에 롱 포지션과 숏 포지션 중 어느 것이 더 유리할지를 나타냅니다. 이 정보는 벡터형 필드에 저장되며, 기업은 여러 개의 뉴스 발표를 가질 수 있습니다. '롱 포지션 이점'이 있는 뉴스 이벤트가 더 많은 주식은 모멘텀을 보일 수 있고, 그러한 이벤트가 적은 기업은 잠재적 반전을 보일 수 있습니다.

vec_avg(nws12_afterhsz_si)를 사용하여 각 기업의 뉴스 데이터에서 평균センチメント를 계산하세요.

ts_sum이나 **ts_mean(ts 연산자)**과 **rank**를 사용하여 적절한 조건을 설정하세요.

if_else나 **<condition>?<if_true>:<if_false>** 형식을 사용하여 알파 아이디어를 구현하세요.

힌트: 시간에 따른 뉴스センチメント(`nws12_afterhsz_si`)의 합에 `rank`를 매겨보세요 -> 높은 순위의 주식 → +1 (모멘텀) -> 낮은 순위의 주식 → 최근 수익률 기반의 숏 포지션 (반전)

예시 답안: `rank(ts_sum(vec_avg(nws12_afterhsz_si),60)) > 0.5 ? 1: -rank(-ts_delta(close_, 2))`

About Sentiment & News Data

데이터 출처:

- センチメント: 소셜 미디어, 뉴스 사이트, 블로그, 포럼
- 뉴스: 재무 보고서, 애널리스트 보고서, 기업 공시

구현 방법

- 1.センチメント 분석
 - `sc112_buzz`와 거래량 활용
 - 시장 심리 지표
 - `ts_regression`을 통한 구현
2. 뉴스 분석
 - `nws12_afterhsz_si` 활용
 - 벡터 평균화 필요
 - 모멘텀/반전 아이디어 결합

사용 가능한 알파 아이디어

- 평균センチメント 계산
- 시계열 연산자 적용
- 순위 기반 조건 설정
- 조건부 로직을 통한 구현

두 접근법 모두 효과적인 시그널 생성을 위해 적절한 데이터 처리와 신중한 조건 설정이 필요합니다.

Let's try out!

センチメント & 뉴스 데이터에 대해 배운 내용을 바탕으로 제출 가능한 알파를 탐구해보세요.

주의사항: 하루에 최대 2,000 챌린지 포인트만 획득할 수 있습니다. 각 알파는 약 1,000에서 2,000 포인트를 획득할 수 있으므로, Gold 레벨에 필요한 10,000 포인트에 도달하려면 5일 이상에 걸쳐 알파를 제출해야 합니다. 하루 최대 획득 가능한 포인트를 고려하여 제출해주세요.

제출 가능한 알파를 만들어보세요!

힌트: 지금까지 배운 내용을 검토하고 제출 가능한 알파를 만들어 보세요. 예시 답안: 직접 문제를 풀어보시기를 권장합니다!